

第二章

强化学习基础

王成龙

wangchenglong@mail.neu.edu.cn

东北大学 计算机科学与工程学院 人工智能系 自然语言处理实验室



東北大學
Northeastern University





强化学习基础

2.1 强化学习建模方法

2.2 强化学习的优化算法

2.3 强化学习的进阶优化算法


2.4 强化学习的应用设计方法

2.5 强化学习方法面临的挑战




2.1 强化学习建模方法

- 2.1.1 马尔可夫决策过程



2.1 强化学习建模方法

• 2.1.1 马尔可夫决策过程



2.1 强化学习建模方法

• 2.1.1 马尔可夫决策过程

那么，如何将这个循环的完整过程形式化？




马尔可夫决策过程 (MDP)

为了完整描述一个MDP，
只需要使用一个五元组就够了



$$M = (\mathcal{S}, \mathcal{A}, P, R, \gamma)$$

两个花体字 $\mathcal{S}$ 和 $\mathcal{A}$ 表示
的都是集合。



2.1 强化学习建模方法

● 2.1.1 马尔可夫决策过程

符号解释（接上页）：

$\mathcal{S}$ 表示状态空间，表达的是：环境究竟能拥有多少
种不同的状态。



世界有哪些状态？

$\mathcal{A}$ 表示动作空间，表达的是：智能体总共能
采取哪些动作。



我能做哪些动作？

P 表示状态转移概率， $P(s'|s,a)$ 表达的是：
在状态 s 下采取动作 a ，下一步进入状态 s'
的概率是多少？



世界因我的动作如何变化？

2.1 强化学习建模方法

• 2.1.1 马尔可夫决策过程

符号解释（接上页）：

R 表示奖励函数，描述了一次动作后，环境产生的即时反馈。

问题：奖励函数应该写成 $R(s,a)$ 还是 $R(s,a,s')$ ，为什么？



我会立刻得到什么奖励？

γ 表示未来的奖励相对于当前奖励有多重要



我多么重视未来奖励？

2.1 强化学习建模方法

• 2.1.1 马尔可夫决策过程

问题：MDP究竟是描述智能体的，还是描述环境的？

实际上，MDP描述的是“环境+任务规则”，而不是智能体本身。 S 和 P 描述的是环境，而另外三个符号描述了任务规则。这些东西合起来，其实是在定义：一个智能体要在什么样的环境中，完成什么样的决策任务。

MDP描述的是环境 + 任务规则，而不是智能体本身



因此，MDP描述的是决策问题，Policy才是用来描述智能体的行为规则的，也就是智能体要如何解决这个决策问题。

2.1 强化学习建模方法

2.1.2 实际例子与五元组的对应





表 2.1: 强化学习基本元素及其在五子棋中的对应关系

对象	数学记号	五子棋中的含义
智能体	—	需要学习落子策略的棋手
环境	—	棋盘规则、胜负判断以及对手行为
环境状态	s_t	完整棋盘、当前行动方及规则所需信息
智能体观测	o_t	实际提供给策略模型的信息；完全可观测时可与 s_t 相同
动作	$a_t \in \mathcal{A}$	在一个合法空位落子
即时奖励	r_t	本次落子及随后转移产生的反馈
策略	$\pi(a s)$	给定局面时各合法落子的选择规则或概率
轨迹	τ	从开局到胜、负或平局的完整交互序列

[1] 五子棋中的强化学习基本元素

2.1 强化学习建模方法

2.1.2 实际例子与五元组的对应



第1步：状态 s_t 与观测 o_t

先看清当前棋局，再决定下一步动作。



1. 智能体 Agent: 下棋模型 / 棋手



2. 环境 Environment: 棋盘 + 规则 + 对手



3. 状态 s_t : 当前完整棋局



4. 观测 o_t : 模型看到的信息 (完全可观测时 $o_t \approx s_t$)




本步重点：先看清当前棋局，再决定下一步动作。

2.1.2 实际例子与五元组的对应

第2步：动作空间 A 与动作 a_t

在当前状态下，哪些落点可以选？本步实际选择哪一个？



1. 动作空间 A :

当前所有合法落点的集合



2. 动作 a_t :

本步实际执行的一步，且 $a_t \in A$



3. 合法动作 :

只能落在空位，不能落在已有棋子上




本步重点： A 表示所有合法落点； a_t 表示本步真正执行的那一步。

2.1 强化学习建模方法

2.1.2 实际例子与五元组的对应


第3步：策略 $\pi(a|s)$ 如何决定动作

策略根据当前状态，为候选落点分配偏好或概率。



- 输入：当前状态 s_t / 观测 o_t
- 输出：对候选动作的分数或概率
- 选择：按策略选择 a_t

候选动作	位置	概率 $\pi(a s_t)$
a_1	H8	0.72
a_2	L13	0.10
a_3	C4	0.08
a_4	L4	0.10



因为 H8 可以直接形成五连，所以策略倾向选择 a_1 。




本步重点：策略 $\pi(a|s)$ 描述智能体在给定状态下如何选择动作。

2.1 强化学习建模方法

2.1.2 实际例子与五元组的对应

第4步：执行动作后，进入下一状态 s_{t+1}

智能体执行 a_t 后，棋局从 s_t 变为 s_{t+1} 。



状态转移：
 $P(s'|s, a)$

描述执行动作后，
环境如何变化



在棋类规则固定时，
给定合法动作后，
状态转移通常是
确定的



黑方在 H8 落子，
形成五连，终局。




本步重点：动作执行后，棋局从 s_t 更新为 s_{t+1} 。

2.1 强化学习建模方法

2.1.2 实际例子与五元组的对应

这一步转移有多好？可以由奖励信号来衡量。



黑方获胜（五连）



五元组 (MDP) : (S, A, P, R, γ)

S 当前棋局； A 合法落点； P 落子后的棋局变化；
 R 胜负反馈； γ 长期回报折扣

第5步： 即时奖励 r_t 与完整回顾




即时奖励 r_t : 对这一步状态转移给出的数值反馈



本例中：黑方形成五连并终局，因此 $r_t = +1$



若不是终局，很多设定中步进奖励通常为 0



强化学习就是让智能体根据状态—动作—奖励信号学习更优策略。

2.1 强化学习建模方法

• 2.1.3 优化目标

随着智能体与环境不断交互，我们就得到了一条具体的轨迹：


$$\tau = (s_0, a_0, r_0, s_1, a_1, r_1, \dots, s_{T-1}, a_{T-1}, r_{T-1}, s_T) \text{ ----- (1)}$$

假设，当环境达到了 s_T 时，任务结束；

而且，我们将每一步获得的奖励都视为同等重要，也就是 $\gamma=1$ 。


我们希望找到一个策略 π ：按照这一策略 π 与环境交互，能够使获得轨迹的平均累计回报较高。

形式化



$$J(\pi) = \mathbb{E}_{\tau \sim p_{\pi}(\tau)} [R(\tau)]$$

目标获得



$$\pi^* = \arg \max_{\pi} J(\pi)$$

问题：策略这个词，到底是什么含义？

策略就是在给定某一个状态下，智能体对动作的概率分布，只不过可以有不同的呈现形式，见下页。

2.1 强化学习建模方法

- 2.1.3 优化目标（接上页）

$$J(\pi) = \mathbb{E}_{\tau \sim p_{\pi}(\tau)}[R(\tau)]$$

上式中的“策略 π ”既可以是简单的表格型策略，也可以用带参数的神经网络表达。



	左	右
s_1	0.2	0.8
s_2	0.7	0.3
s_3	0.1	0.9



$$s \xrightarrow{\text{Neural Network}_{\theta}} \text{logits} \xrightarrow{\text{softmax}} \pi_{\theta}(a|s).$$

2.1 强化学习建模方法

- 2.1.3 优化目标 (接上页)

$$J(\pi) = \mathbb{E}_{\tau \sim p_{\pi}(\tau)}[R(\tau)]$$

问题：优化目标中的 $p_{\pi}(\tau)$ 是什么？ 它表示：参数化的策略 π_{θ} 诱导出的轨迹的分布

$$\tau = (s_0, a_0, r_0, s_1, a_1, r_1, \dots, s_{T-1}, a_{T-1}, r_{T-1}, s_T)$$

假设对于上面的轨迹来说，初始状态： $s_0 \sim \rho_0(s_0)$ ，
则上面所写的任意一条轨迹的概率都可以记作：

$$p_{\theta}(\tau) = \rho_0(s_0) \prod_{t=0}^{T-1} \pi_{\theta}(a_t | s_t) P(s_{t+1} | s_t, a_t)$$

这些轨迹共同组成了一个概率分布！



强化学习基础

2.1 强化学习建模方法

2.2 强化学习的优化算法

2.3 强化学习的进阶优化算法

2.4 强化学习的应用设计方法

2.5 强化学习方法的挑战



2.2 强化学习的优化算法

● 2.2.1 基于价值函数的方法

从前面一节的描述中，我们明白了：
强化学习的目的是寻找最优策略，
那么要怎么寻找这个最优策略？

方法一：利用动作价值函数（Bellman期望方程）

Bellman期望方程的形式

$$Q^{\pi}(s, a) = \mathbb{E} \left[r + \gamma \sum_{a'} \pi(a' | s') Q^{\pi}(s', a') \right]$$



$$Q^{\pi}(s, a) = \sum_{s', r} p(s', r | s, a) \left[r + \gamma \sum_{a'} \pi(a' | s') Q^{\pi}(s', a') \right]$$

问题：Bellman期望方程，
仅仅是一个方程，还是一个方程组？

因为式子中的s和a可以有很多个不同选择，
我们能得到 $|\mathcal{S}| |\mathcal{A}|$ 条相互耦合的标量方程，
所以是方程组。

2.2 强化学习的优化算法

● 2.2.1 基于价值函数的方法

方法一：利用动作价值函数（Bellman期望方程）

方法一核心思路：

- 1.假设我们已经求到了Bellman方程的值，也就是：在任何一个状态下，做任何一个动作，最终平均能得到多少回报。
- 2.那么只要：在任何一个状态下，选择Q最大的那个动作即可。

第一步就是策略评估，方法是迭代Bellman期望方程；

第二步就是策略改进，方法是： $\pi_k = \arg \max_a Q^{\pi_{k-1}}(s, a)$

反复循环这两步，我们就可以求得最优策略。


2.2 强化学习的优化算法

● 2.2.1 基于价值函数的方法

方法二：利用最优动作价值函数（Bellman最优方程）

Bellman最优方程的形式

$$Q^*(s, a) = \mathbb{E} \left[r + \gamma \max_{a'} Q^*(s', a') \right]$$



展开

$$Q^*(s, a) = \sum_{s', r} p(s', r | s, a) \left[r + \gamma \max_{a'} Q^*(s', a') \right]$$

问题：Bellman最优方程中，等式右侧的 $\max$ 操作，是什么含义？

在状态 s 先执行动作 a ，获得即时奖励 r 并到达 s' ；从下一状态开始，始终选择价值最高的动作。

因此， $\max$ 操作只作用于下一状态的动作 a' ，当前动作 a 并没有参与这个 $\max$ 。

注意：无论是Bellman期望方程，还是Bellman最优方程，在求解时都很难一步求出结果。可以通过后面的例子进行理解。

2.2 强化学习的优化算法

● 2.2.1 基于价值函数的方法

方法二：利用最优动作价值函数（Bellman最优方程）

方法二核心思路：


1. 假设我知道，在任何一个状态 s ，做出任何一个动作 a ，从下一个状态开始，每一步都选择最优动作，最终平均能获得多少回报，并将结果记作 $Q^*(s, a)$ ，也就是求解完了Bellman最优方程，
2. 那么最后，只需要再额外做一次： $\pi^*(s) = \arg \max_a Q^*(s, a)$ ，就得到了在任何一个状态 s 下，应该做哪个动作的最优策略。



我完全听不懂？
下面举个例子！

2.2 强化学习的优化算法

● 2.2.1 基于价值函数的方法




[1] 网格世界的动作奖励

一个策略评估的例子：如何计算给定策略下的状态价值？

在这个网格世界中，当智能体到达s4的位置，就可以获得1的奖励，其余时刻获得的都是0的奖励，假设现在智能体的策略如图中的绿线所示，我们如何对这个策略进行策略评估？

2.2 强化学习的优化算法

● 2.2.1 基于价值函数的方法



[1] 网格世界的动作奖励

一个策略评估的例子：如何计算给定策略下的状态价值？

在这个网格世界中，当智能体到达s4的位置，就可以获得1的奖励，其余时刻获得的都是0的奖励，假设现在智能体的策略如图中的绿线所示，我们如何对这个策略进行策略评估？

直接对状态s
列出Bellman
期望方程：


$$\begin{cases} v_1 = 0 + \gamma * v_3 \\ v_2 = 1 + \gamma * v_4 \\ v_3 = 1 + \gamma * v_4 \\ v_4 = 1 + \gamma * v_4 \end{cases}$$

注意，对于图中的
确定性策略：

$$V^\pi(s) = Q^\pi(s, \pi(s))$$

2.2 强化学习的优化算法

2.2.1 基于价值函数的方法



[1] 网格世界的动作奖励

一个策略评估的例子：如何计算给定策略下的状态价值？

在这个网格世界中，当智能体到达s4的位置，就可以获得1的奖励，其余时刻获得的都是0的奖励，假设现在智能体的策略如图中的绿线所示，我们如何对这个策略进行策略评估？

直接对状态s
列出Bellman
期望方程：

$$\begin{cases} v_1 = 0 + \gamma * v_3 \\ v_2 = 1 + \gamma * v_4 \\ v_3 = 1 + \gamma * v_4 \\ v_4 = 1 + \gamma * v_4 \end{cases}$$

注意，对于图中的
确定性策略：


$$V^\pi(s) = Q^\pi(s, \pi(s))$$

整理后得到：

$$\begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 1 \\ 1 \end{bmatrix} + \gamma * \begin{bmatrix} 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix}$$

2.2 强化学习的优化算法

• 2.2.1 基于价值函数的方法



[1] 网格世界的动作奖励


$$\begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 1 \\ 1 \end{bmatrix} + \gamma * \begin{bmatrix} 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix}$$

虽然上面的方程组很好求解，但当矩阵维度极大时，我们经常使用数值分析中的Jacobi迭代法或者Gauss-Seidel迭代法求解线性方程组。

将矩阵方程写成： $v^{(k+1)} = r^\pi + \gamma * P_\pi * v^{(k)}$ 后，一步一步迭代。

2.2 强化学习的优化算法

• 2.2.1 基于价值函数的方法



[1] 网络世界的动作奖励

$$\begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 1 \\ 1 \end{bmatrix} + \gamma * \begin{bmatrix} 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix}$$

虽然上面的方程组很好求解，但当矩阵维度极大时，我们经常使用数值分析中的Jacobi迭代法或者Gauss-Seidel迭代法求解线性方程组。

将矩阵方程写成： $v^{(k+1)} = r^\pi + \gamma * P_\pi * v^{(k)}$ 后，一步一步迭代。

问题：假设初始的 v^0 = 零向量， $\gamma = 0.5$ ，
请写出一、二、三次迭代后的 v 向量。

如果直接使用矩阵逆运算： $v^\pi = (I - \gamma P_\pi)^{-1} * r_\pi$ ，
得到的解析解是多少？


2.2 强化学习的优化算法

● 2.2.1 基于价值函数的方法

那么策略改进是在做什么？

为了找到最优策略，一个暴力的想法：假设我可以对所有既定策略，都进行策略评估，那是不是可以从中挑出一个最好的策略？

不行！假设有 $|S|$ 个状态，每个状态最多可以执行 $|A|$ 个动作，那么确定性策略的数量是指数级的，不可能枚举完。更何况智能体也可以执行非确定性策略。




[1] 网格世界的动作奖励

讲义上，对基于Bellman最优方程的Q-Learning进行了详细讲解，请同学们课后学习。

2.2 强化学习的优化算法

● 2.2.1 基于价值函数的方法

那么策略改进是在做什么？



[1] 网格世界的动作奖励

为了找到最优策略，一个暴力的想法：假设我可以对所有既定策略，都进行策略评估，那是不是可以从中挑出一个最好的策略？

策略改进的神奇之处就在这里！

假设一开始的策略是 π_0 ，我们已经完成了对它的策略评估，它的含义是：如果接下来一直使用 π_0 行动，最终平均可以获得多少回报。

策略改进的含义是，假设在某个状态时，仅这一步采取一个新的动作，而后续仍然遵照 π_0 行动，那么最终平均可以获得多少回报。

于是，这就为我们在当前这一步，采取什么动作会更好，提供了依据。

讲义上，对基于Bellman最优方程的Q-Learning进行了详细讲解，请同学们课后学习。

2.2 强化学习的优化算法

● 2.2.1 基于价值函数的方法 (补充内容, 感兴趣可以自行学习)

前面的网格世界场景, 包含了两个理想化假设:

1. 环境转移方程已知: 我们完全了解执行每一步动作后, 环境会转移到哪里, 以及转移到对应位置的概率。
2. 状态空间很小: 我们能够枚举所有状态, 并保存完整的Q表。

1. 假设不知道环境模型怎么办?
此时应该怎么估计 Q^π ?

2. 状态太多, Q表存不下怎么办?

蒙特卡洛预测——First-Visit MC和Every-Visit MC
时序差分预测和控制——SARSA、Q-Learning

值函数近似—— $Q(s, a; \theta)$

2.2 强化学习的优化算法

● 2.2.2 基于策略优化的方法

基于价值函数的方法首先回答：每个动作的价值是多少，然后再选择价值最高的动作。

换句话说，求解动作价值函数并不是我们最终的目的。

那么，既然强化学习的目标就是求解最优策略，那有没有直接一点的方法？

也就是说，我们其实希望的是：当模型按照某一个策略行动时，最后的平均收益最大，如果这件事情能够直接被形式化，我们就不需要绕远，费力气求解动作价值了。

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法

$$J(\pi) = \mathbb{E}_{\tau \sim p_{\pi}(\tau)} [R(\tau)]$$

我们仍从上式出发，但因为我们使用了神经网络做为带参数的策略，所以等价地改写成右边式子：

$$J(\theta) = \mathbb{E}_{\tau \sim \mathcal{D}} [R(\tau) | \pi_{\theta}]$$

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法

$$J(\pi) = \mathbb{E}_{\tau \sim p_{\pi}(\tau)} [R(\tau)]$$

我们仍从上式出发，但因为我们使用了神经网络做为带参数的策略，所以等价地改写成右边式子：

$$\begin{aligned} J(\theta) &= \mathbb{E}_{\tau \sim \mathcal{D}} [R(\tau) | \pi_{\theta}] \\ &= \sum_{\tau \in \mathcal{D}} \text{Pr}_{\theta}(\tau) R(\tau) \end{aligned}$$

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法

$$J(\pi) = \mathbb{E}_{\tau \sim p_{\pi}(\tau)} [R(\tau)]$$

我们仍从上式出发，但因为我们使用了神经网络做为带参数的策略，所以等价地改写成右边式子：

$$\begin{aligned} J(\theta) &= \mathbb{E}_{\tau \sim \mathcal{D}} [R(\tau) | \pi_{\theta}] \\ &= \sum_{\tau \in \mathcal{D}} \text{Pr}_{\theta}(\tau) R(\tau) \\ &= \sum_{\tau \in \mathcal{D}} \text{Pr}_{\theta}(\tau) \sum_{t=1}^T r_t \end{aligned}$$

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法

$$J(\pi) = \mathbb{E}_{\tau \sim p_{\pi}(\tau)} [R(\tau)]$$

我们仍从上式出发，但因为我们使用了神经网络做为带参数的策略，所以等价地改写成右边式子：

$$\begin{aligned} J(\theta) &= \mathbb{E}_{\tau \sim \mathcal{D}} [R(\tau) | \pi_{\theta}] \\ &= \sum_{\tau \in \mathcal{D}} \text{Pr}_{\theta}(\tau) R(\tau) \\ &= \sum_{\tau \in \mathcal{D}} \text{Pr}_{\theta}(\tau) \sum_{t=1}^T r_t \end{aligned}$$

我们的目标就是获得 $\tilde{\theta}$ ，使得 $\tilde{\theta} = \arg \max_{\theta} J(\theta)$

2.2 强化学习的优化算法

● 2.2.2 基于策略优化的方法

我们已经得到了关于神经网络参数 θ 的性能函数：

$$\begin{aligned} J(\theta) &= \mathbb{E}_{\tau \sim \mathcal{D}} [R(\tau) | \pi_{\theta}] \\ &= \sum_{\tau \in \mathcal{D}} \text{Pr}_{\theta}(\tau) R(\tau) \\ &= \sum_{\tau \in \mathcal{D}} \text{Pr}_{\theta}(\tau) \sum_{t=1}^T r_t \end{aligned}$$

问题：如何对它求导？

一些前置的数学技巧：

1. 复合函数的对数求导 (Log-derivative trick)

$$\nabla_{\theta} \log f_{\theta} = \frac{\nabla_{\theta} f_{\theta}}{f_{\theta}} \Rightarrow \nabla_{\theta} f_{\theta} = f_{\theta} * \nabla_{\theta} \log f_{\theta}$$

进一步将 f_{θ} 替换成轨迹概率 $\text{Pr}_{\theta}(\tau)$ ，得到：

$$\nabla_{\theta} \text{Pr}_{\theta}(\tau) = \text{Pr}_{\theta}(\tau) * \nabla_{\theta} \log \text{Pr}_{\theta}(\tau)$$

2. 乘积取对数变成求和

因为： $\text{Pr}_{\theta}(\tau) \propto \prod_{t=1}^T \pi_{\theta}(a_t | s_t)$,

所以： $\log \text{Pr}_{\theta}(\tau) = \text{与}\theta\text{无关的项} + \sum_{t=1}^T \log \pi_{\theta}(a_t | s_t)$

进一步求导： $\nabla_{\theta} \text{Pr}_{\theta}(\tau) = \frac{\partial \log \text{Pr}_{\theta}(\tau)}{\partial \theta} = \frac{\partial}{\partial \theta} \sum_{t=1}^T \log \pi_{\theta}(a_t | s_t)$

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法

下面对性能函数求导：

$$\begin{aligned}\frac{\partial J(\theta)}{\partial \theta} &= \frac{\partial \sum_{\tau \in \mathcal{D}} \text{Pr}_{\theta}(\tau) R(\tau)}{\partial \theta} \\ &= \sum_{\tau \in \mathcal{D}} \frac{\partial \text{Pr}_{\theta}(\tau)}{\partial \theta} R(\tau) \quad \Rightarrow \quad \text{交换求和与求导的顺序}\end{aligned}$$

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法

下面对性能函数求导：

$$\begin{aligned}\frac{\partial J(\theta)}{\partial \theta} &= \frac{\partial \sum_{\tau \in \mathcal{D}} \Pr_{\theta}(\tau) R(\tau)}{\partial \theta} \\ &= \sum_{\tau \in \mathcal{D}} \frac{\partial \Pr_{\theta}(\tau)}{\partial \theta} R(\tau) \quad \Longrightarrow \quad \text{交换求和与求导的顺序} \\ &= \sum_{\tau \in \mathcal{D}} \Pr_{\theta}(\tau) \frac{\partial \Pr_{\theta}(\tau) / \partial \theta}{\Pr_{\theta}(\tau)} R(\tau) \quad \Longrightarrow \quad \text{凑出前面提到的对数求导的形式}\end{aligned}$$

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法

下面对性能函数求导：

$$\begin{aligned}\frac{\partial J(\theta)}{\partial \theta} &= \frac{\partial \sum_{\tau \in \mathcal{D}} \Pr_{\theta}(\tau) R(\tau)}{\partial \theta} \\ &= \sum_{\tau \in \mathcal{D}} \frac{\partial \Pr_{\theta}(\tau)}{\partial \theta} R(\tau) \quad \Rightarrow \text{交换求和与求导的顺序} \\ &= \sum_{\tau \in \mathcal{D}} \Pr_{\theta}(\tau) \frac{\partial \Pr_{\theta}(\tau) / \partial \theta}{\Pr_{\theta}(\tau)} R(\tau) \quad \Rightarrow \text{凑出前面提到的} \\ &= \sum_{\tau \in \mathcal{D}} \Pr_{\theta}(\tau) \frac{\partial \log \Pr_{\theta}(\tau)}{\partial \theta} R(\tau) \quad \text{对数求导的形式}\end{aligned}$$

2.2 强化学习的优化算法


• 2.2.2 基于策略优化的方法

接上页结论：

$$\begin{aligned}\frac{\partial J(\theta)}{\partial \theta} &= \frac{\partial \sum_{\tau \in \mathcal{D}} \Pr_{\theta}(\tau) R(\tau)}{\partial \theta} \\ &= \sum_{\tau \in \mathcal{D}} \frac{\partial \Pr_{\theta}(\tau)}{\partial \theta} R(\tau) \\ &= \sum_{\tau \in \mathcal{D}} \Pr_{\theta}(\tau) \frac{\partial \Pr_{\theta}(\tau) / \partial \theta}{\Pr_{\theta}(\tau)} R(\tau) \\ &= \sum_{\tau \in \mathcal{D}} \Pr_{\theta}(\tau) \frac{\partial \log \Pr_{\theta}(\tau)}{\partial \theta} R(\tau)\end{aligned}$$

再对其中的轨迹概率求导数：

$$\frac{\partial \log \Pr_{\theta}(\tau)}{\partial \theta} = \frac{\partial}{\partial \theta} \log \prod_{t=1}^T \pi_{\theta}(a_t | s_t) \Pr(s_{t+1} | s_t, a_t)$$



展开整条轨迹的概率，
可结合左图理解

2.2 强化学习的优化算法

• 2.2.2 基于策略优化的方法

接上页结论：

$$\begin{aligned}\frac{\partial J(\theta)}{\partial \theta} &= \frac{\partial \sum_{\tau \in \mathcal{D}} \Pr_{\theta}(\tau) R(\tau)}{\partial \theta} \\ &= \sum_{\tau \in \mathcal{D}} \frac{\partial \Pr_{\theta}(\tau)}{\partial \theta} R(\tau) \\ &= \sum_{\tau \in \mathcal{D}} \Pr_{\theta}(\tau) \frac{\partial \Pr_{\theta}(\tau) / \partial \theta}{\Pr_{\theta}(\tau)} R(\tau) \\ &= \sum_{\tau \in \mathcal{D}} \Pr_{\theta}(\tau) \frac{\partial \log \Pr_{\theta}(\tau)}{\partial \theta} R(\tau)\end{aligned}$$

再对其中的轨迹概率求导数：

$$\begin{aligned}\frac{\partial \log \Pr_{\theta}(\tau)}{\partial \theta} &= \frac{\partial}{\partial \theta} \log \prod_{t=1}^T \pi_{\theta}(a_t | s_t) \Pr(s_{t+1} | s_t, a_t) \\ &= \frac{\partial}{\partial \theta} \sum_{t=1}^T \underbrace{\log \pi_{\theta}(a_t | s_t)}_{\text{policy}} + \frac{\partial}{\partial \theta} \sum_{t=1}^T \underbrace{\log \Pr(s_{t+1} | s_t, a_t)}_{\text{dynamics}}\end{aligned}$$



它是0，为什么？

2.2 强化学习的优化算法

• 2.2.2 基于策略优化的方法

接上页结论：

$$\begin{aligned}\frac{\partial J(\theta)}{\partial \theta} &= \frac{\partial \sum_{\tau \in \mathcal{D}} \Pr_{\theta}(\tau) R(\tau)}{\partial \theta} \\ &= \sum_{\tau \in \mathcal{D}} \frac{\partial \Pr_{\theta}(\tau)}{\partial \theta} R(\tau) \\ &= \sum_{\tau \in \mathcal{D}} \Pr_{\theta}(\tau) \frac{\partial \Pr_{\theta}(\tau) / \partial \theta}{\Pr_{\theta}(\tau)} R(\tau) \\ &= \sum_{\tau \in \mathcal{D}} \Pr_{\theta}(\tau) \frac{\partial \log \Pr_{\theta}(\tau)}{\partial \theta} R(\tau)\end{aligned}$$

再对其中的轨迹概率求导数：


$$\begin{aligned}\frac{\partial \log \Pr_{\theta}(\tau)}{\partial \theta} &= \frac{\partial}{\partial \theta} \log \prod_{t=1}^T \pi_{\theta}(a_t | s_t) \Pr(s_{t+1} | s_t, a_t) \\ &= \frac{\partial}{\partial \theta} \sum_{t=1}^T \underbrace{\log \pi_{\theta}(a_t | s_t)}_{\text{policy}} + \frac{\partial}{\partial \theta} \sum_{t=1}^T \underbrace{\log \Pr(s_{t+1} | s_t, a_t)}_{\text{dynamics}} \\ &= \frac{\partial}{\partial \theta} \sum_{t=1}^T \underbrace{\log \pi_{\theta}(a_t | s_t)}_{\text{policy}}\end{aligned}$$

2.2 强化学习的优化算法

• 2.2.2 基于策略优化的方法

接上页结论：

$$\begin{aligned}\frac{\partial J(\theta)}{\partial \theta} &= \frac{\partial \sum_{\tau \in \mathcal{D}} \Pr_{\theta}(\tau) R(\tau)}{\partial \theta} \\ &= \sum_{\tau \in \mathcal{D}} \frac{\partial \Pr_{\theta}(\tau)}{\partial \theta} R(\tau) \\ &= \sum_{\tau \in \mathcal{D}} \Pr_{\theta}(\tau) \frac{\partial \Pr_{\theta}(\tau) / \partial \theta}{\Pr_{\theta}(\tau)} R(\tau) \\ &= \sum_{\tau \in \mathcal{D}} \Pr_{\theta}(\tau) \frac{\partial \log \Pr_{\theta}(\tau)}{\partial \theta} R(\tau)\end{aligned}$$



再对其中的轨迹概率求导数：

$$\begin{aligned}\frac{\partial \log \Pr_{\theta}(\tau)}{\partial \theta} &= \frac{\partial}{\partial \theta} \log \prod_{t=1}^T \pi_{\theta}(a_t | s_t) \Pr(s_{t+1} | s_t, a_t) \\ &= \frac{\partial}{\partial \theta} \sum_{t=1}^T \underbrace{\log \pi_{\theta}(a_t | s_t)}_{\text{policy}} + \frac{\partial}{\partial \theta} \sum_{t=1}^T \underbrace{\log \Pr(s_{t+1} | s_t, a_t)}_{\text{dynamics}} \\ &= \frac{\partial}{\partial \theta} \sum_{t=1}^T \underbrace{\log \pi_{\theta}(a_t | s_t)}_{\text{policy}}\end{aligned}$$

带入

最后，假设从数据集 $\mathcal{D}$ 中抽出的 $|\mathcal{D}|$ 条轨迹，
概率相同，于是可以将 $\Pr_{\theta}(\tau)$ 写成： $\frac{1}{|\mathcal{D}|}$ ，最终得到：

$$\frac{\partial J(\theta)}{\partial \theta} = \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \frac{\partial}{\partial \theta} \left(\sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) \sum_{t=1}^T r_t \right)$$

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法

接上页结论：

$$\frac{\partial J(\theta)}{\partial \theta} = \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \frac{\partial}{\partial \theta} \left(\sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) \sum_{t=1}^T r_t \right)$$

问题：推导这么多，我们该如何理解这个梯度表达式的语义？

2.2 强化学习的优化算法

● 2.2.2 基于策略优化的方法

$$\begin{aligned}\frac{\partial J(\theta)}{\partial \theta} &= \frac{\partial \sum_{\tau \in \mathcal{D}} \text{Pr}_{\theta}(\tau) R(\tau)}{\partial \theta} \\&= \sum_{\tau \in \mathcal{D}} \frac{\partial \text{Pr}_{\theta}(\tau)}{\partial \theta} R(\tau) \\&= \sum_{\tau \in \mathcal{D}} \text{Pr}_{\theta}(\tau) \frac{\partial \text{Pr}_{\theta}(\tau) / \partial \theta}{\text{Pr}_{\theta}(\tau)} R(\tau) \\&= \sum_{\tau \in \mathcal{D}} \text{Pr}_{\theta}(\tau) \frac{\partial \log \text{Pr}_{\theta}(\tau)}{\partial \theta} R(\tau) \\&= \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \frac{\partial}{\partial \theta} \left(\sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) \sum_{t=1}^T r_t \right)\end{aligned}$$

对这个式子的理解：

首先，式子中的 J 并不是损失函数，而是性能函数，它是越大越好，而不是越小越好。

其次，左侧的式子是一个求和式，而我们知道梯度是一个向量，每一条采样出的轨迹都为总梯度提供一个方向，我们可以只挑出其中的任意一条轨迹进行研究，此时左侧式子中的 $\text{Pr}_{\theta}(\tau)$ 这一项就可以被忽略。

于是这条轨迹 τ 就为总梯度提供了一个方向： $R(\tau) * \nabla_{\theta} \log \text{Pr}_{\theta}(\tau)$ 。（类似于物理中的分力）

如果现在只观察某一条采样到的轨迹 τ ，并直接利用它更新 $J(\theta)$ ，它对应的随机梯度更新就是：

$$\theta' = \theta + \alpha * R(\tau) * \nabla_{\theta} \log \text{Pr}_{\theta}(\tau)$$

2.2 强化学习的优化算法

• 2.2.2 基于策略优化的方法

$$\begin{aligned}\frac{\partial J(\theta)}{\partial \theta} &= \frac{\partial \sum_{\tau \in \mathcal{D}} \text{Pr}_{\theta}(\tau) R(\tau)}{\partial \theta} \\ &= \sum_{\tau \in \mathcal{D}} \frac{\partial \text{Pr}_{\theta}(\tau)}{\partial \theta} R(\tau) \\ &= \sum_{\tau \in \mathcal{D}} \text{Pr}_{\theta}(\tau) \frac{\partial \text{Pr}_{\theta}(\tau) / \partial \theta}{\text{Pr}_{\theta}(\tau)} R(\tau) \\ &= \sum_{\tau \in \mathcal{D}} \text{Pr}_{\theta}(\tau) \frac{\partial \log \text{Pr}_{\theta}(\tau)}{\partial \theta} R(\tau)\end{aligned}$$

接上页:

如果现在只观察某一条采样到的轨迹 τ ，若直接利用它优化 $J(\theta)$ ，它对应的随机梯度更新就是：

$$\theta' = \theta + \alpha * R(\tau) * \nabla_{\theta} \log \text{Pr}_{\theta}(\tau)$$

那么，优化器为了让 $J(\theta)$ 增大，等价于让 θ 沿着 $R(\tau) * \nabla_{\theta} \log \text{Pr}_{\theta}(\tau)$ 所指向的方向变化。而当 $R(\tau)$ 这个值为正，也就是说，某一条轨迹非常好，那么 θ 变化的方向，就和 $\nabla_{\theta} \log \text{Pr}_{\theta}(\tau)$ 完全一致，而前面推导过： $\nabla_{\theta} \log \text{Pr}_{\theta}(\tau) = \frac{\nabla_{\theta} \text{Pr}_{\theta}(\tau)}{\text{Pr}_{\theta}(\tau)}$ ，分母始终为正，则 $\nabla_{\theta} \log \text{Pr}_{\theta}(\tau)$ 的方向和 $\nabla_{\theta} \text{Pr}_{\theta}(\tau)$ 的方向完全相同。而根据梯度的定义， θ 变化的方向，将使 $\text{Pr}_{\theta}(\tau)$ 变大，也就是增加这条“好轨迹”出现的概率。这就是策略梯度定理的含义。

2.2 强化学习的优化算法

• 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

$$\frac{\partial J(\theta)}{\partial \theta} = \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \frac{\partial}{\partial \theta} \left(\sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) \sum_{t=1}^T r_t \right)$$

在上式中，假设G是从时刻一到时刻T的奖励的总和，而X是从时刻一到时刻T的对数概率的梯度的求和。

可以证明存在某个baseline,

当 $(G - baseline) * X$ 后，方差不会大于 $G * X$ ；在满足特定条件时，方差会严格减小（这里不做证明，感兴趣的同学可以自己研究一下）。

我们推导减去某个特定方差后的策略梯度定理：

$$\begin{aligned} \frac{\partial J(\theta)}{\partial \theta} &= \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \frac{\partial}{\partial \theta} \left(\sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) \right) \left(\sum_{t=1}^T r_t - b \right) \\ &= \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \frac{\partial}{\partial \theta} \left[\sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) \left(\sum_{k=1}^T r_k - b \right) \right] \end{aligned}$$



问题：这一步为什么要引入中间变量k？

2.2 强化学习的优化算法

• 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

$$\frac{\partial J(\theta)}{\partial \theta} = \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \frac{\partial}{\partial \theta} \left(\sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) \sum_{t=1}^T r_t \right)$$

在上式中，假设G是从时刻一到时刻T的奖励的总和，而X是从时刻一到时刻T的对数概率的梯度的求和。

可以证明存在某个baseline,

当 $(G - baseline) * X$ 后，方差不会大于 $G * X$ ；在满足特定条件时，方差会严格减小（这里不做证明，感兴趣的同学可以自己研究一下）。

我们推导减去某个特定方差后的策略梯度定理：

在上式中，假设G是从时刻一到时刻T的奖励的总和，而X是从时刻一到时刻T的对数概率的梯度的求和。

可以证明存在某个baseline,

当 $(G - baseline) * X$ 后，方差不会大于 $G * X$ ；在满足特定条件时，方差会严格减小（这里不做证明，感兴趣的同学可以自己研究一下）。



问题：这一步为什么要引入中间变量k？

答案：为了把轨迹的总奖励拆分为“动作发生前”和“动作发生后”两部分。

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

接上页：

$$\begin{aligned}\frac{\partial J(\theta)}{\partial \theta} &= \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \frac{\partial}{\partial \theta} \left(\sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) \right) \left(\sum_{t=1}^T r_t - b \right) \\ &= \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \frac{\partial}{\partial \theta} \left[\sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) \left(\sum_{k=1}^T r_k - b \right) \right] \\ &= \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \frac{\partial}{\partial \theta} \left[\sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) \left(\sum_{k=1}^{t-1} r_k + \sum_{k=t}^T r_k - b \right) \right]\end{aligned}$$

进一步化简：

$$\frac{\partial J(\theta)}{\partial \theta} = \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \frac{\partial}{\partial \theta} \left[\sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) \left(\sum_{k=t}^T r_k - b \right) \right]$$

2.2 强化学习的优化算法

• 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

接上页：

$$\begin{aligned}\frac{\partial J(\theta)}{\partial \theta} &= \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \frac{\partial}{\partial \theta} \left(\sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) \right) \left(\sum_{t=1}^T r_t - b \right) \\ &= \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \frac{\partial}{\partial \theta} \left[\sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) \left(\sum_{k=1}^T r_k - b \right) \right] \\ &= \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \frac{\partial}{\partial \theta} \left[\sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) \left(\sum_{k=1}^{t-1} r_k + \sum_{k=t}^T r_k - b \right) \right]\end{aligned}$$

问题：这一项为什么是0？只有它是0，我们才能从左侧式子中将它去掉

$$\mathbb{E} \left[\sum_{t=1}^T \left(\sum_{k=1}^{t-1} r_k \right) \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right] = 0$$

进一步化简：

$$\frac{\partial J(\theta)}{\partial \theta} = \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \frac{\partial}{\partial \theta} \left[\sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) \left(\sum_{k=t}^T r_k - b \right) \right]$$

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

接上页问题：这一项为什么是0？


$$\mathbb{E}_{\tau \sim p_{\theta}} \left[\sum_{t=1}^T \left(\sum_{k=1}^{t-1} R_k \right) \nabla_{\theta} \log \pi_{\theta}(A_t | S_t) \right] = 0$$

期望是对轨迹取的，
也就是： $\mathbb{E}_{\tau \sim p_{\theta}(\tau)}[\dots]$

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

接上页问题：这一项为什么是0？


$$\mathbb{E}_{\tau \sim p_{\theta}} \left[\sum_{t=1}^T \left(\sum_{k=1}^{t-1} R_k \right) \nabla_{\theta} \log \pi_{\theta}(A_t | S_t) \right] = 0$$

期望是对轨迹取的，
也就是： $\mathbb{E}_{\tau \sim p_{\theta}(\tau)}[\dots]$

为什么这里的R、A、S
被偷偷换成了大写字母？

概率论中通常约定：

大写字母表示随机变量；

小写字母表示随机变量的一次具体取值。

例如： S_t 、 A_t 、 R_t 表示在采样轨迹之前，
尚不确定的状态、动作和奖励。而一旦采
样出一条具体轨迹，它们的实际取值记为：

$S_t = s_t$ ， $A_t = a_t$ 和 $R_t = r_t$ 。

2.2 强化学习的优化算法

● 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

接上页问题：这一项为什么是0？


$$\mathbb{E}_{\tau \sim p_{\theta}} \left[\sum_{t=1}^T \left(\sum_{k=1}^{t-1} R_k \right) \nabla_{\theta} \log \pi_{\theta}(A_t | S_t) \right] = 0$$

期望是对轨迹取的，
也就是： $\mathbb{E}_{\tau \sim p_{\theta}(\tau)}[\dots]$

上一页中的公式因为使用的是有限数据集 $\mathcal{D}$ ，
所以 s_t ， a_t 和 r_t 都是已经观察到的样本值，
因此使用小写字母

$$\mathbb{E} \left[\sum_{t=1}^T \left(\sum_{k=1}^{t-1} r_k \right) \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right] = 0$$

为什么这里的R、A、S
被偷偷换成了大写字母？

概率论中通常约定：

大写字母表示随机变量；

小写字母表示随机变量的一次具体取值。



例如： S_t 、 A_t 、 R_t 表示在采样轨迹之前，
尚不确定的状态、动作和奖励。而一旦采样出一条具体轨迹，它们的实际取值记为：
 $S_t = s_t$ ， $A_t = a_t$ 和 $R_t = r_t$ 。

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

接上页问题：这一项为什么是0？

$$\mathbb{E}_{\tau \sim p_{\theta}} \left[\sum_{t=1}^T \left(\sum_{k=1}^{t-1} R_k \right) \nabla_{\theta} \log \pi_{\theta}(A_t | S_t) \right] = 0$$

期望是对轨迹取的，
也就是： $\mathbb{E}_{\tau \sim p_{\theta}(\tau)} [\dots]$

期望的线性性质 $\Downarrow$ 调换 $\sum_{t=1}^T$ 和 $\mathbb{E}_{\tau \sim p_{\theta}}$ 的顺序

$$= \sum_{t=1}^T \mathbb{E}_{\tau \sim p_{\theta}} \left[\left(\sum_{k=1}^{t-1} R_k \right) \nabla_{\theta} \log \pi_{\theta}(A_t | S_t) \right]$$

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

接上页问题：这一项为什么是0？

$$\mathbb{E}_{\tau \sim p_{\theta}} \left[\sum_{t=1}^T \left(\sum_{k=1}^{t-1} R_k \right) \nabla_{\theta} \log \pi_{\theta}(A_t | S_t) \right] = 0$$

期望是对轨迹取的，
也就是： $\mathbb{E}_{\tau \sim p_{\theta}(\tau)}[\dots]$

期望的线性性质 $\Downarrow$ 调换 $\sum_{t=1}^T$ 和 $\mathbb{E}_{\tau \sim p_{\theta}}$ 的顺序

$$= \sum_{t=1}^T \mathbb{E}_{\tau \sim p_{\theta}} \left[\left(\sum_{k=1}^{t-1} R_k \right) \nabla_{\theta} \log \pi_{\theta}(A_t | S_t) \right]$$

只要证明其中任意一个时间步 t_0 对应的期望为零，
那么所有时间步相加后仍然为零，不失一般性地
将 t_0 记成 t 。


$$\mathbb{E}_{\tau \sim p_{\theta}} \left[\left(\sum_{k=1}^{t-1} R_k \right) \nabla_{\theta} \log \pi_{\theta}(A_t | S_t) \right]$$

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

接上页，调换期望与求和号顺序，并固定考虑单个时间步 t

$$\mathbb{E}_{\tau \sim p_{\theta}} \left[\left(\sum_{k=1}^{t-1} R_k \right) \nabla_{\theta} \log \pi_{\theta}(A_t | S_t) \right]$$



对大量轨迹 τ ，考虑历史前缀


$$= \mathbb{E}_{H_t} \left[\mathbb{E}_{A_t \sim \pi_{\theta}(\cdot | S_t)} \left[\left(\sum_{k=1}^{t-1} R_k \right) \nabla_{\theta} \log \pi_{\theta}(A_t | S_t) \right] \right]$$

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

接上页，调换期望与求和号顺序，并固定考虑单个时间步 t

$$\mathbb{E}_{\tau \sim p_{\theta}} \left[\left(\sum_{k=1}^{t-1} R_k \right) \nabla_{\theta} \log \pi_{\theta}(A_t | S_t) \right]$$



对大量轨迹 τ ，考虑历史前缀

$$= \mathbb{E}_{H_t} \left[\mathbb{E}_{A_t \sim \pi_{\theta}(\cdot | S_t)} \left[\left(\sum_{k=1}^{t-1} R_k \right) \nabla_{\theta} \log \pi_{\theta}(A_t | S_t) \right] \right]$$

什么是 H_t ?

在时刻 t 选择动作 A_t 之前，已经发生的全部信息称为历史

$$H_t = (S_1, A_1, R_1, \dots, S_{t-1}, A_{t-1}, R_{t-1}, S_t)$$

因此，在给定 H_t 后，过去的累积奖励 $\sum_{k=1}^{t-1} R_k$ 将被确定下来

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

接上页，引入历史前缀：

$$= \mathbb{E}_{H_t} \left[\mathbb{E}_{A_t \sim \pi_\theta(\cdot | S_t)} \left[\left(\sum_{k=1}^{t-1} R_k \right) \nabla_\theta \log \pi_\theta(A_t | S_t) \right] \right]$$

暂时不管 $\mathbb{E}_{H_t}$

先考虑内层期望

$$\mathbb{E}_{A_t \sim \pi_\theta(\cdot | S_t)} \left[\left(\sum_{k=1}^{t-1} R_k \right) \nabla_\theta \log \pi_\theta(A_t | S_t) \right]$$

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

接上页，考虑内层期望：

$$\mathbb{E}_{A_t \sim \pi_\theta(\cdot | S_t)} \left[\left(\sum_{k=1}^{t-1} R_k \right) \nabla_\theta \log \pi_\theta(A_t | S_t) \right]$$

既然历史 H_t 已经固定，那么，

$R_1, R_2, \dots, R_{t-1}$ 已经全部发生，过去的累积奖励 $\sum_{k=1}^{t-1} R_k$ 是一个确定值。

内层期望只对当前动作 A_t 的随机性取平均，所以过去奖励可以从期望符号中提出来。
也就是说，当给定历史之后，过去奖励不再随当前动作的选择而变化。

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）


接上页，考虑内层期望：

$$\mathbb{E}_{A_t \sim \pi_\theta(\cdot | S_t)} \left[\left(\sum_{k=1}^{t-1} R_k \right) \nabla_\theta \log \pi_\theta(A_t | S_t) \right]$$

既然历史 H_t 已经固定，那么，

$R_1, R_2, \dots, R_{t-1}$ 已经全部发生，过去的累积奖励 $\sum_{k=1}^{t-1} R_k$ 是一个确定值。

内层期望只对当前动作 A_t 的随机性取平均，所以过去奖励可以从期望符号中提出来。
也就是说，当给定历史之后，过去奖励不再随当前动作的选择而变化。



$$= \left(\sum_{k=1}^{t-1} R_k \right) \mathbb{E}_{A_t \sim \pi_\theta(\cdot | S_t)} [\nabla_\theta \log \pi_\theta(A_t | S_t)]$$

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

接上页，提出过去累积奖励：

$$= \left(\sum_{k=1}^{t-1} R_k \right) \mathbb{E}_{A_t \sim \pi_{\theta}(\cdot | S_t)} [\nabla_{\theta} \log \pi_{\theta}(A_t | S_t)]$$

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

接上页，提出过去累积奖励：

$$= \left(\sum_{k=1}^{t-1} R_k \right) \mathbb{E}_{A_t \sim \pi_{\theta}(\cdot | S_t)} [\nabla_{\theta} \log \pi_{\theta}(A_t | S_t)]$$

展开上式中的动作期望部分：

$$\begin{aligned} & \mathbb{E}_{A_t \sim \pi_{\theta}(\cdot | S_t)} [\nabla_{\theta} \log \pi_{\theta}(A_t | S_t)] \\ &= \sum_a \pi_{\theta}(a | S_t) \nabla_{\theta} \log \pi_{\theta}(a | S_t) \\ &= \sum_a \pi_{\theta}(a | S_t) \frac{\nabla_{\theta} \pi_{\theta}(a | S_t)}{\pi_{\theta}(a | S_t)} \\ &= \sum_a \nabla_{\theta} \pi_{\theta}(a | S_t) = \nabla_{\theta} \sum_a \pi_{\theta}(a | S_t) = \nabla_{\theta} \mathbf{1} = 0. \end{aligned}$$

因此乘上过去累积奖励，也仍然是0。

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

$$\begin{aligned} & \mathbb{E}_{A_t \sim \pi_\theta(\cdot | S_t)} [\nabla_\theta \log \pi_\theta(A_t | S_t)] \\ &= \sum_a \pi_\theta(a | S_t) \nabla_\theta \log \pi_\theta(a | S_t) \end{aligned}$$

举例理解一下这个公式：

假设： $\pi_\theta(a_1 | s) = p_\theta$, $\pi_\theta(a_2 | s) = 1 - p_\theta$.

$$\begin{aligned} & \mathbb{E}[\nabla_\theta \log \pi_\theta(A_t | s)] \\ &= p_\theta \nabla_\theta \log p_\theta + (1 - p_\theta) \nabla_\theta \log(1 - p_\theta) \\ &= \nabla_\theta p_\theta - \nabla_\theta p_\theta \\ &= 0. \end{aligned}$$

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

$$\begin{aligned} & \mathbb{E}_{A_t \sim \pi_\theta(\cdot | S_t)} [\nabla_\theta \log \pi_\theta(A_t | S_t)] \\ &= \sum_a \pi_\theta(a | S_t) \nabla_\theta \log \pi_\theta(a | S_t) \end{aligned}$$

举例理解一下这个公式：

假设： $\pi_\theta(a_1 | s) = p_\theta$, $\pi_\theta(a_2 | s) = 1 - p_\theta$.

$$\begin{aligned} & \mathbb{E}[\nabla_\theta \log \pi_\theta(A_t | s)] \\ &= p_\theta \nabla_\theta \log p_\theta + (1 - p_\theta) \nabla_\theta \log(1 - p_\theta) \\ &= \nabla_\theta p_\theta - \nabla_\theta p_\theta \\ &= 0. \end{aligned}$$

因此，调整参数 θ ，本质上只是在不同动作之间重新分配概率。
某些动作的概率增加，另外一些动作的概率必然减少。
所有动作概率变化量的总和必然是零。

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

接上页，引入历史前缀：

$$= \mathbb{E}_{H_t} \left[\mathbb{E}_{A_t \sim \pi_\theta(\cdot | S_t)} \left[\left(\sum_{k=1}^{t-1} R_k \right) \nabla_\theta \log \pi_\theta(A_t | S_t) \right] \right]$$

暂时不管 $\mathbb{E}_{H_t}$

考虑内层期望，是0


$$\mathbb{E}_{A_t \sim \pi_\theta(\cdot | S_t)} \left[\left(\sum_{k=1}^{t-1} R_k \right) \nabla_\theta \log \pi_\theta(A_t | S_t) \right]$$

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

接上页，引入历史前缀：

$$= \mathbb{E}_{H_t} \left[\mathbb{E}_{A_t \sim \pi_\theta(\cdot | S_t)} \left[\left(\sum_{k=1}^{t-1} R_k \right) \nabla_\theta \log \pi_\theta(A_t | S_t) \right] \right]$$

暂时不管 $\mathbb{E}_{H_t}$  考虑内层期望，是0

$$\mathbb{E}_{A_t \sim \pi_\theta(\cdot | S_t)} \left[\left(\sum_{k=1}^{t-1} R_k \right) \nabla_\theta \log \pi_\theta(A_t | S_t) \right]$$

恢复外层期望，就是把不同历史，
按照它们出现的概率加权平均，仍然是0。

$$= \mathbb{E}_{H_t} [0] = 0$$

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

$$\mathbb{E}_{\tau \sim p_{\theta}} \left[\sum_{t=1}^T \left(\sum_{k=1}^{t-1} R_k \right) \nabla_{\theta} \log \pi_{\theta}(A_t | S_t) \right] = 0$$

证明过程总结：

对于采样出的大量轨迹，我们考虑任意一个时间步；
在每一个时间步下，此时不同轨迹具有不同的历史 H_t ，
我们按照 H_t 的取值对不同轨迹进行分组，在每一个分组内部，
历史 H_t 将被固定；

假设固定某个历史 $H_t = h_t^{(1)}$ ，在大量到达该历史的轨迹中，
大约 $\frac{N_1}{N} \approx \pi_{\theta}(a_1 | s_t)$ 的比例选择 a_1 ，大约 $\frac{N_2}{N} \approx \pi_{\theta}(a_2 | s_t)$ 的
比例选择 a_2 ，以此类推……，因此随着样本数趋近无穷，
样本平均值： $\sum_i \frac{N_i}{N} * \nabla_{\theta} \log \pi_{\theta}(a_i | s_t)$ 就趋近为0。

假设固定某个历史 $H_t = h_t^{(2)}$ ，在大量到达该历史的轨迹中，
我们仍能得到相同的，平均值为0的结论……
因此最终的总期望就是0。

2.2 强化学习的优化算法

- 2.2.2 基于策略优化的方法（动作的信用分配并引入奖励基线）

$$\begin{aligned}\frac{\partial J(\theta)}{\partial \theta} &= \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \frac{\partial}{\partial \theta} \left(\sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) \right) \left(\sum_{t=1}^T r_t - b \right) \\ &= \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \frac{\partial}{\partial \theta} \left[\sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) \left(\sum_{k=1}^T r_k - b \right) \right] \\ &= \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \frac{\partial}{\partial \theta} \left[\sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) \left(\sum_{k=1}^{t-1} r_k + \sum_{k=t}^T r_k - b \right) \right]\end{aligned}$$

进一步化简：

$$\frac{\partial J(\theta)}{\partial \theta} = \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \frac{\partial}{\partial \theta} \left[\sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) \left(\sum_{k=t}^T r_k - b \right) \right]$$

对第48页PPT的总结：
第t步动作只可能影响从t开始的奖励；
因此，用 $G_t = \sum_{k=t}^T r_k$ 代替整条轨迹
回报，能够减少无关噪声；
再减去与动作无关的baseline，可以
进一步降低梯度估计的方差。

2.2 强化学习的优化算法

● 2.2.3 Actor-Critic框架

前面我们推导出：

$$\frac{\partial J(\theta)}{\partial \theta} = \frac{1}{|\mathcal{D}|} \sum_{\tau \in \mathcal{D}} \frac{\partial}{\partial \theta} \left[\sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) \left(\sum_{k=t}^T r_k - b \right) \right]$$

那么这里的基线应该怎么选择？一个很自然的想法是：在某个状态 s_t 下，平均最终可以获得多少回报？也就是选择：

$$b(s_t) = V^{\pi}(s_t) = \mathbb{E}[G_t | s_t].$$

如果我们将 $\sum_{k=t}^T r_k$ 记作 G_t ，那么 $G_t - V^{\pi}(s_t)$ 自然可以表达：这一条轨迹获得的回报，相比从该状态出发通常能够获得的回报，高了多少或低了多少。

问题： $V^{\pi}(s_t)$ 这个值怎么求，我们根本不知道它的真实值？

答案是训练一个价值网络 ϕ ，使得： $V_{\phi}(s_t) \approx V^{\pi}(s_t)$ 。

这个网络不负责选择动作，只负责评价当前状态，因此称为：Critic；


而原来的策略网络 $\pi_{\theta}(a_t | s_t)$ 负责选择动作，因此称为：Actor。

2.2 强化学习的优化算法

● 2.2.3 Actor-Critic框架

但是，如果仍然使用 G_t ，就必须等整条轨迹结束，我们才能获得：

$$G_t = r_t + \gamma * r_{t+1} + \gamma^2 * r_{t+2} + \dots,$$
之后使用 $G_t - V^\pi(s_t)$ 做为轨迹好坏的判定方式。
那么能不能让Critic仅观察Actor做一步动作，就立刻进行评价？



2.2 强化学习的优化算法

2.2.3 Actor-Critic框架

下面我们引出优势函数。

我们知道： $Q^\pi(s, a) = \mathbb{E}_\pi[G_t | S_t = s, A_t = a]$ ，定义： $A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s)$ 。

因此， G_t 就是 $Q^\pi(s, a)$ 的蒙特卡洛估计，


而 $G_t - V^\pi(s_t)$ 就是优势函数 $A^\pi(s, a)$ 的蒙特卡洛估计。

注意：为了简洁，图中画的树形图不太标准，状态和动作往往使用空心圆和实心圆做区分，一个空心圆也可以分支出多个实心圆。

可参考下面的经典教程：

<https://chizkidd.github.io/RL-Sutton-Barto-notes/chapters/ch03-finite-mdps.html>

1) $Q^\pi(s, a)$ 的定义



$$G_t^{(1)} = r_t^{(1)} + \gamma r_{t+1}^{(1)} + \gamma^2 r_{t+2}^{(1)} + \dots$$

$$Q^\pi(s, a) = \mathbb{E}_\pi[G_t | s_t = s, a_t = a]$$

固定状态和动作后，未来随机回报的平均值

2) $V^\pi(s)$ 的定义

$$V^\pi(s) = \mathbb{E}_\pi[G_t | s_t = s]$$

只固定状态时的平均回报

3) $A^\pi(s, a)$ 的定义与意义

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s)$$

优势：该动作比该状态下平均水平好多少

因此： G_t 是 $Q^\pi(s, a)$ 的蒙特卡洛估计；
 $G_t - V^\pi(s_t)$ 是 $A^\pi(s, a)$ 的蒙特卡洛估计。

2.2 强化学习的优化算法

• 2.2.3 Actor-Critic框架

接下来，我们将 G_t 的表达式递归地改写为：

$$G_t = r_t + \gamma * G_{t+1},$$

因此，前面 $A^\pi(s, a) \approx G_t - V^\pi(s_t)$ ，就可以进一步写成：

$$A^\pi(s, a) \approx r_t + \gamma * G_{t+1} - V^\pi(s_t), \text{ 之后利用下面等式:}$$

$$G_{t+1} \approx V^\pi(s_{t+1}),$$

重新带入： $A^\pi(s, a) \approx r_t + \gamma * V^\pi(s_{t+1}) - V^\pi(s_t)$ ，因此一个网络可以同时承担两个不同时刻的状态价值的预测！

因此我们不需要MC估计了，可以直接使用1-TD error了。这就是Actor-Critic算法的原理。

问题：为什么 G_t 可以同时成为 $V^\pi(s)$ 和 $Q^\pi(s, a)$ 的蒙特卡洛估计？

答案：对于同一个随机变量，当我们以不同的方式看待它，取不同的条件概率时，就会有不同的含义：

$$V^\pi(s) = \mathbb{E}[G_t | s_t = s],$$

$$Q^\pi(s, a) = \mathbb{E}[G_t | s_t = s, a_t = a]$$





强化学习基础

2.1 强化学习建模方法

2.2 强化学习的优化算法

2.3 强化学习的进阶优化算法

2.4 强化学习的应用设计方法


2.5 强化学习方法挑战



2.3.1 近端策略优化方法


- Actor-Critic 回顾

Actor 负责输出动作，价值网络 Critic 评估状态优劣，
用 Critic 的评价反馈指导 Actor 更新策略




2.3.1 近端策略优化方法

● Actor-Critic 回顾



2.3.1 近端策略优化方法

● Actor-Critic 回顾



例子


旧策略: $\pi_{\text{old}}(a|s) = 0.40$

Critic: $A^{\pi_{\text{old}}}(s, a) = +2$

Critic: 从当前策略附近看, 应该提高 a 的概率。

2.3.1 近端策略优化方法

● Actor-Critic 回顾



例子

旧策略: $\pi_{\text{old}}(a|s) = 0.40$

Critic: $A^{\pi_{\text{old}}}(s, a) = +2$

Critic: 从当前策略附近看, 应该提高 a 的概率。

Critic 回答: 在 π_{old} 经常到达的状态 s 上, 动作 a 相比 π_{old} 的平均行为, 是更好还是更差。

2.3.1 近端策略优化方法

- Actor-Critic 的问题：有方向，但没有“这一步能走多远”的约束

2.3.1 近端策略优化方法

- Actor-Critic 的问题：有方向，但没有“这一步能走多远”的约束



2.3.1 近端策略优化方法


- Actor-Critic 的问题：有方向，但没有“这一步能走多远”的约束



2.3.1 近端策略优化方法

- Actor-Critic 的问题：有方向，但没有“这一步能走多远”的约束


为什么“大步更新”会让旧优势估计越来越不可靠？



2.3.1 近端策略优化方法

- Actor-Critic 的问题：有方向，但没有“这一步能走多远”的约束


为什么“大步更新”会让旧优势估计越来越不可靠？



2.3.1 近端策略优化方法

- Actor-Critic 的问题：有方向，但没有“这一步能走多远”的约束

为什么“大步更新”会让旧优势估计越来越不可靠？



2.3.1 近端策略优化方法

- **近端策略优化 (Proximal Policy Optimization, PPO)**
- 把 “新策略不要离旧策略太远” 直接写进优化目标

2.3.1 近端策略优化方法

- 近端策略优化 (Proximal Policy Optimization, PPO)
- 把 “新策略不要离旧策略太远” 直接写进优化目标

第一步：量化 “改了多少”

$$r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{old}(a_t|s_t)}$$

$$r_t \approx 1$$

新旧策略在这个动作上的概率接近

$$r_t \gg 1 \text{ 或 } r_t \ll 1$$

说明这一步把动作概率改得很激进

2.3.1 近端策略优化方法

- 近端策略优化 (Proximal Policy Optimization, PPO)
- 把 “新策略不要离旧策略太远” 直接写进优化目标

第一步：量化 “改了多少”

$$r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{old}(a_t|s_t)}$$

$r_t \approx 1$ 新旧策略在这个动作上的概率接近

$r_t \gg 1$ 或 $r_t \ll 1$ 说明这一步把动作概率改得很激进

例： $\pi_{old}(a|s) = 0.40$

$0.48 \rightarrow r = 1.20$ $0.95 \rightarrow r = 2.375$

2.3.1 近端策略优化方法

- 近端策略优化 (Proximal Policy Optimization, PPO)
- 把 “新策略不要离旧策略太远” 直接写进优化目标

第一步：量化 “改了多少”

$$r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{old}(a_t|s_t)}$$

$r_t \approx 1$

新旧策略在这个动作上的概率接近

$r_t \gg 1$ 或
 $r_t \ll 1$

说明这一步把动作概率改得很激进

例： $\pi_{old}(a|s) = 0.40$

$0.48 \rightarrow r = 1.20$ $0.95 \rightarrow r = 2.375$

第二步：Clipping 不再奖励 “继续走远”

L^{CLIP}

$$= \mathbb{E}[\min(r_t A_t, \text{clip}(r_t, 1 - \epsilon, 1 + \epsilon) A_t)]$$

当 $A_t > 0$:

可以提高动作概率，但提高到一定程度后，目标函数不再继续给额外奖励。

当 $A_t < 0$:

可以降低动作概率，但也不鼓励一次降得过头。

2.3.1 近端策略优化方法

- 近端策略优化 (Proximal Policy Optimization, PPO)
- 把 “新策略不要离旧策略太远” 直接写进优化目标

第一步：量化 “改了多少”

$$r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{old}(a_t|s_t)}$$

$r_t \approx 1$ 新旧策略在这个动作上的概率接近

$r_t \gg 1$ 或 $r_t \ll 1$ 说明这一步把动作概率改得很激进

例： $\pi_{old}(a|s) = 0.40$

$0.48 \rightarrow r = 1.20$ $0.95 \rightarrow r = 2.375$

第二步：Clipping 不再奖励 “继续走远”

$$L^{CLIP} = \mathbb{E}[\min(r_t A_t, \text{clip}(r_t, 1 - \varepsilon, 1 + \varepsilon) A_t)]$$

当 $A_t > 0$: 可以提高动作概率，但提高到一定程度后，目标函数不再继续给额外奖励。

当 $A_t < 0$: 可以降低动作概率，但也不鼓励一次降得过头。

PPO 的核心：让 π_{new} 保持在 π_{old} 的 “可信邻域” 内，再重新采样、再更新。

2.3.2 离线强化学习方法

- 有些任务不能让当前策略不断在线试错

医疗决策

新策略不能为了探索，随机给病人尝试未经验证的治疗路径。



2.3.2 离线强化学习方法

- 有些任务不能让当前策略不断在线试错

医疗决策

新策略不能为了探索，随机给病人尝试未经验证的治疗路径。



自动驾驶


不能把每天刚更新的策略直接部署到真实道路上“边撞边学”。



2.3.2 离线强化学习方法

- 离线强化学习解决的是固定数据下的分布外泛化问题

只有固定历史数据，训练中
不能再在线收集



2.3.2 离线强化学习方法

- **在线强化学习可以继续采样；离线强化学习只使用预先收集并固定的数据集。**

训练时只能**从历史数据中学习**，不能再让目标策略进入环境补充它最缺少的样本。

2.3.2 离线强化学习方法

- 在线强化学习可以继续采样；离线强化学习只使用预先收集并固定的数据集。

训练时只能从历史数据中学习，不能再让目标策略进入环境补充它最缺少的样本。

在线强化学习

当前策略
 $\pi(a|s)$



环境交互
rollout

不断采新数据，当前策略可以边学边试。

2.3.2 离线强化学习方法

- 在线强化学习可以继续采样；离线强化学习只使用预先收集并固定的数据集。

训练时只能从历史数据中学习，不能再让目标策略进入环境补充它最缺少的样本。

在线强化学习

当前策略
 $\pi(a|s)$



环境交互
rollout

不断采新数据，当前策略可以边学边试。

离线强化学习

固定数据集
历史轨迹 $\mathcal{D}$



策略 / 价值
学习

训练期间不能再进环境，只能利用已有数据推断更好的策略。



强化学习基础

2.1 强化学习建模方法

2.2 强化学习的优化算法

2.3 强化学习的进阶优化算法

2.4 强化学习的应用设计方法

2.5 强化学习方法挑战



2.4.1 任务边界与转移定义

- 先固定“谁在决策”以及“一个时间步到哪里结束”
任务边界（以下五子棋举例）

智能体：黑方策略


**负责选择当前黑方
回合的落子位置**

环境：白方 + 规则

**执行合法性检查、黑
子落下、白方回应与
终止判定**


2.4.1 任务边界与转移定义

- 先固定“谁在决策”以及“一个时间步到哪里结束”
转移定义



2.4.1 任务边界与转移定义

- 先固定“谁在决策”以及“一个时间步到哪里结束”
转移定义




比较算法时应冻结：环境版本、对手来源、开局分布、终止规则。
否则性能差异无法只归因于算法。

2.4.2 状态表示与动作空间

- 状态表示要与“策略实际能看到的**信息**”一致
- 动作空间、掩码与坐标编码必须和环境**严格一致**

2.4.2 状态表示与动作空间


- 状态表示要与“策略实际能看到的信息”一致
- 动作空间、掩码与坐标编码必须和环境严格一致



棋盘完全可见，且策略只在黑方回合调用

2.4.2 状态表示与动作空间

- 状态表示要与“策略实际能看到的信息”一致
- 动作空间、掩码与坐标编码必须和环境严格一致



棋盘完全可见，且策略只在黑方回合调用

- 已有棋子的格点：规则上非法，直接屏蔽
- “棋力很差”的落子：仍然合法，不应被启发式掩码删除

2.4.3 奖励与约束

- 先定义核心目标，再谨慎加入过程奖励

核心奖励

胜
+1

负
-1

平
0

非终止步骤: $r_t = 0$

优点：目标直接

难点：信用分配距离长

2.4.3 奖励与约束

- 先定义核心目标，再谨慎加入过程奖励

核心奖励

优点：目标直接
难点：信用分配距离长

加入辅助奖励

$$r_t = r_t^{\text{task}} + \sum_{i=1}^K \lambda_i r_t^{(i)}$$


λ_i 不能只比较单步大小，还要估算整
回合累计上限与出现频率

2.4.3 训练与评估过程设计

训练

- 采集 / 探索
- 更新参数
- 监控优化指标

不能用训练回报宣称
最终性能




2.4.3 训练与评估过程设计

验证

- 比较检查点
- 选择超参数
- 早停与失败诊断

不能把反复调参后的验证结果当无偏测试




2.4.3 训练与评估过程设计

最终测试

- 冻结方案
- 报告任务指标
- 报告波动

不能继续选模型、改奖励或
回流数据





强化学习基础

2.1 强化学习建模方法

2.2 强化学习的优化算法

2.3 强化学习的进阶优化算法


2.4 强化学习的应用设计方法

2.5 强化学习方法的挑战



2.5 强化学习方法的挑战

- 训练回报上升，并不意味着策略真的可靠



① 训得动吗？——规模与覆盖

状态、动作与轨迹规模巨大

② 训得稳吗？——稳定性与泛化


换种子、换场景后是否有效

③ 学对了吗？——奖励构建

Reward上升是否等于真实目标

2.5.1 面向大规模决策的挑战


- 状态空间太大，无法靠“记忆”解决



- 棋盘规模：15×15=225 个格点
- 状态维度：每个格点有 3 种状态
(空 / 黑 / 白)
- 状态上界： 3^{225}

2.5.1 面向大规模决策的挑战

- 状态空间太大，无法靠“记忆”解决



- 棋盘规模：15×15=225 个格点
- 状态维度：每个格点有 3 种状态
(空 / 黑 / 白)
- 状态上界：3²²⁵



状态空间爆炸！

无法遍历全部状态，也无法为每个状态单独保存价值

2.5.1 面向大规模决策的挑战

- 函数近似解决了存储问题，但没有解决覆盖问题

表格形式的价值函数


每个状态单独存一个值

一般形式: $s_i \rightarrow V(s_i)$

2.5.1 面向大规模决策的挑战

- 函数近似解决了存储问题，但没有解决覆盖问题


表格形式的价值函数



每个状态单独存一个值

一般形式: $s_i \rightarrow V(s_i)$

神经网络近似价值函数




用共享参数拟合 $V_{(s)}$

$V_{\Phi}(s) \rightarrow V^{\pi}(s)$


2.5.1 面向大规模决策的挑战

- 动作空间变大后，探索也会变难

若每步 b 个动作、共 H 步，则动作空间约为 b^H




局部棋盘动作筛选示意




2.5.1 面向大规模决策的挑战

● 降低大动作空间的决策难度



候选筛选

- 优点：缩小候选范围
- 缺点：可能把真正最优动作提前排除




分解动作

- 优点：降低单次输出规模
- 缺点：延长决策过程


2.5.1 面向大规模决策的挑战

- 长决策序列带来信用分配问题



2.5.1 面向大规模决策的挑战

- 长决策序列带来信用分配问题



回合长度为 T ，时刻 t 的动作需要考虑之后的全部奖励：

$$G_t = \sum_{k=t}^{T-1} \gamma^{k-t} r_k$$

r_k ：时刻 k 的即时奖励


$\gamma \in (0,1)$ ：折扣因子

不能简单靠减小折扣因子解决，还需要更准确的价值估计、合理过程反馈或分层任务结构

2.5.1 面向大规模决策的挑战

- 大规模问题会提高环境交互成本

缓解方法（一）：并行采样




采样更快 $\neq$ 需要的数据更少

2.5.1 面向大规模决策的挑战

- 大规模问题会提高环境交互成本

缓解方法（二）：模拟环境




2.5.1 面向大规模决策的挑战


- 大规模问题会提高环境交互成本

缓解方法（三）：课程学习


简单局面
(较小棋盘)



预设
中期局面




完整棋盘/
完整对局



先处理较简单的状态和任务，再逐渐增加环境复杂度

2.5.2 强化学习训练的不稳定性和泛化性问题

● 如何判断训练不稳定




波动可能原因

- **样本**: 是否过少而放大偶然轨迹
- **Actor**: 是否移动过快
- **Critic**: 是否在变化的数据上产生系统偏差
- **探索**: 是否过早消失或长期过强, 影响收敛

2.5.2 强化学习训练的不稳定性和泛化性问题



● 如何判断训练不稳定



波动可能原因

- **样本**: 是否过少而放大偶然轨迹
- **Actor**: 是否移动过快
- **Critic**: 是否在变化的数据上产生系统偏差
- **探索**: 是否过早消失或长期过强, 影响收敛

解决方法



- 监控价值目标、KL散度、策略熵等指标
- 梯度裁剪
- 多随机种子重复实验
-

2.5.2 强化学习训练的不稳定性和泛化性问题

● 泛化问题——模型只是“记住了”训练环境


训练环境 (单一)

① 总是同一个对手



学会针对固定弱点


② 总是固定开局



只熟悉少数常见模型


测试环境 (变化)

① 换一个对手



对手改变，胜率下降


② 随机合法开局/中间局面



未见局面适应能力有限


2.5.2 强化学习训练的不稳定性和泛化性问题

● 解决方法——防止“死记硬背”




对手池

引入不同水平、棋风和历史版本策略，防止特化



域随机化

随机化初始状态
与非核心特征




对称数据增强

利用旋转/翻转等价局面


2.5.3 强化学习方法的奖励构建问题

- 奖励升高，也可能学错了目标



2.5.3 强化学习方法的奖励构建问题

- 奖励升高，也可能学错了目标



$$\pi_R^* = \arg \max_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{T-1} \gamma^t R(s_t, a_t, s_{t+1}) \right]$$


算法直接优化：奖励 R

真正关心的是：任务效用 U

$$R \uparrow \neq U \uparrow$$

2.5.3 强化学习方法的奖励构建问题

● 典型问题——代理目标错位




候选A：做活三
(代理指标更高)

候选B：防守
(更接近真实目标)

2.5.3 强化学习方法的奖励构建问题

● 典型问题——奖励投机 (Reward Hacking)




投机策略：形成“活三”加一分

实际目标：连成五子击败对手

2.5.3 强化学习方法的奖励构建问题

● 典型问题——信用分配

只有**结果奖励**




- 更接近最终任务目标
- 但反馈稀疏，信用分配困难

2.5.3 强化学习方法的奖励构建问题


- 过程奖励缩短信号延迟，但也会引入人类偏好

只有**结果奖励**



- 更接近最终任务目标
- 但反馈稀疏，信用分配困难

加入**过程奖励**



- 缩短信号延迟
- 但会把人工判断写进目标

2.5.3 强化学习方法的奖励构建问题

- 多目标奖励：权重代表任务取舍

$$r_t = \sum_{i=1}^K \lambda_i r_t^{(i)}$$

2.5.3 强化学习方法的奖励构建问题

- 多目标奖励：权重代表任务取舍

$$r_t = \sum_{i=1}^K \lambda_i r_t^{(i)} \longrightarrow \text{第 } i \text{ 个目标在时刻 } t \text{ 的奖励}$$

(可为正向奖励或惩罚)

2.5.3 强化学习方法的奖励构建问题

- 多目标奖励：权重代表任务取舍


$$r_t = \sum_{i=1}^K \lambda_i r_t^{(i)}$$

↓
第 i 个目标的权重

2.5.3 强化学习方法的奖励构建问题

- 多目标奖励：权重代表任务取舍

$$r_t = \sum_{i=1}^K \lambda_i r_t^{(i)}$$



2.5.3 强化学习方法的奖励构建问题

● 如何判断奖励设计有没有问题

- ✓ 独立指标监控：保留与训练奖励不同源的评估信号，观察其他指标是否真实提高
- ✓ 轨迹审计：抽取高回报、低回报、指标冲突和约束边界附近的轨迹，检查其分数获得
- ✓ 奖励消融实验：去掉某个奖励，核心目标的表现是否反而更好
- ✓ 权重敏感性实验：微调 λ_i ，观察行为是否发生预期变化