

第五讲

多模态机器学习方法与模型

肖桐

xiaotong@mail.neu.edu.cn

东北大学 计算机科学与工程学院 人工智能系 自然语言处理实验室



東北大學
Northeastern University



5.1 多模态表示学习与跨模态对齐

5.1 多模态表示学习与跨模态对齐



什么是模态?

5.1 多模态表示学习与跨模态对齐


- 同一只猫的三种模态



图像模态

猫
cat

文本模态



音频模态

不同模态但指向相同语义。

5.1 多模态表示学习与跨模态对齐

- 多模态表示学习研究：

图像、语音与文本如何从原始数据转化为模型可处理的向量表示；

- 跨模态对齐研究：

不同模态的表示如何在同一空间中建立语义对应，即跨模态对齐。

5.1.1 单模态表示

在这一小节中我们将学习每个模态
在计算机里是怎么表示的

5.1.1 单模态表示

• 计算机眼里的三种模态

图像：像素矩阵

30	200	255
128	90	15
60	180	240

每格为 0-255 的整数
($H \times W \times 3$)

语音：采样点（振幅）

文本：词表编号

“一只猫”

↓ 查词表

[15, 352]

每个词对应一个编号

为什么不能直接使用三种模态
在计算机里的原始数字表示，
而需要将它们向量化？


图像 = $H \times W \times 3$ 的整数矩阵（每像素取值范围 0-255）

语音 = 随时间的一维振幅序列（若采样率 16 kHz → 每秒 16000 个数字）


文本 = 词表编号序列（“猫” → 编号数字 352）

5.1.1 单模态表示

- 为什么要用向量“重新表示”？



像素相同但语义不同



编号相邻但语义无关

5.1.1 单模态表示

- 用向量表示对象：向量 = 一组特征




$$\text{向量 } x = \begin{bmatrix} \text{有毛} \\ \text{有轮子} \\ \text{黑色} \\ \text{绿色} \\ \text{动物} \\ \dots \end{bmatrix} = \begin{bmatrix} 0.8 \\ 0.03 \\ 0.6 \\ 0.1 \\ 0.9 \\ \dots \end{bmatrix}$$

注意：真实特征由数据自动学出，但每个数都代表一个含义，
这里向量 x 的每个数共同描述了猫

5.1.1 单模态表示

- 使用向量描述的好处是



- 三种模态都能用向量统一表示，能把他们放在同一个空间
- 如果他们所处的语义空间一致，那么语义相近的事物不管来自哪个模态，他们所处的位置就相近（这是他们的原始表示做不到的）

5.1.1 单模态表示

- 图像表示学习

如何把一张图像变成神经网络能理解的向量？



一般而言我们可以使用卷积神经网络和 Transformer 提取图片特征，接下来我们将介绍他们的网络结构。

5.1.1 单模态表示

- 图像表示学习

方法一：使用卷积（神经网络）提取图片特征

——以边缘检测为例

5.1.1 单模态表示

- 图像编码：卷积

0	255	255
0	0	255
0	0	255

3	3	3
3	3	3
3	3	3

×

-1	0	1
-2	0	2
-1	0	1

=

1020


=

0

数值越大，则
边缘越明显

5.1.1 单模态表示

- 例：卷积做边缘检测



边缘检测


取一个用于检测竖直边缘的 3×3 卷积核，在图像上滑动，即可在灰度变化剧烈的竖直边缘处得到较大响应、在颜色平坦处得到接近 0 的响应，从而“**点亮**”物体的竖直轮廓。

每个位置我们都能获得一个“**是否是边缘**”的特征。

换用不同的卷积核，我们就能获得描述这张图片的很多不同的特征。

5.1.1 单模态表示

- 例：VGG



VGG堆叠卷积核、激活函数、池化（和卷积类似，这里的Max-Pool是取2*2区域内最大的值作为该区域的代表特征值），最终可以获得1000个特征

5.1.1 单模态表示


- 图像表示学习

方法二：使用 Transformer 提取图片特征

——以 Vision Transformer 为例

5.1.1 单模态表示

● 例：Vision Transformer (ViT)



Vision Transformer不依赖卷积，而是把图像切成固定大小的图块（patch），每个图块经线性映射成一个向量，即一个视觉 token，随后用自注意力建模这些 token 间的关系。

Vision Transformer (ViT)

5.1.1 单模态表示

- 音频的表示学习


如何把一段音频变成神经网络能理解的向量？



5.1.1 单模态表示

- 如何把一段语音变成神经网络能理解的向量？

(a) 波形 (Waveform)：一维振幅采样序列




语音在计算机中的原始形式是**一维波形**，即按时间顺序记录的振幅采样点序列。

若采样率为 16000 Hz，则一秒语音包含 16000 个数值。

5.1.1 单模态表示


- 语音表示：从波形到声学 token



一种经典处理方式是把波形转换为频谱图。

5.1.1 单模态表示

- 语音表示：从波形到声学 token




人耳对不同频率的分辨能力并不均匀，低频区域更敏感，因此语音处理中还常将频谱**投影到梅尔尺度**上，得到**梅尔频谱**。

5.1.1 单模态表示

- 使用 Transformer 提取音频特征 (以 WavLM 为例)

和图像类似，音频也可以使用 卷积 和 Transformer 提取特征。



z_i 是对应帧的 k-means 聚类伪标签

5.1.1 单模态表示

- 文本的表示学习

如何把一段文本变成神经网络能理解的向量？



5.1.1 单模态表示

- 文本表示：分词、词表与词嵌入

以“一只猫”为例：


- 先切分为“一只” “猫” 两个 token
- 查词表得到各自编号
- 再经词嵌入表取出对应向量。

于是一句话最终成为一串词向量，与图像的视觉 token、语音的声学 token 在形式上一致。

5.1.1 单模态表示

● 三模态殊途同归

图像、语音、文本最终都整理成“大模型可处理的一串向量”。



形式统一只是第一步，它们还各在不同空间，下面介绍自监督学习和跨模态对齐。

5.1.2 自监督学习与预训练表示

上一小节中我们介绍了：

每个模态的原始表示和向量表示，以及对应的编码器。

在这一小节中我们将学习：

如何获取强大的编码器，使编码后的向量有良好的表征。

自监督学习是我们训练强大编码器的利器！

5.1.2 自监督学习与预训练表示

● 自监督学习的概念

自监督学习是一种无监督学习范式。

其核心思想是：从无标注数据中自动构造监督信号，让模型通过预测数据自身的结构或变换关系来学习通用特征表示，再迁移到下游任务（如分类、检测）中。

其优点为：

无需人工标注

监督信号来自数据本身（如遮挡补全、旋转预测、实例判别），极大降低数据标注成本，可大规模利用未标注数据。

泛化能力强


学到的特征更具通用性和鲁棒性，能在多种下游任务（分类、分割、检索）上取得接近或超过有监督预训练的效果。

可扩展性极强

适用于图像、文本、语音、视频等多种模态，且数据量越大，性能提升越明显（符合“规模定律”）。

5.1.2 自监督学习与预训练表示


- 图像自监督之一：掩码重建 (MAE)



随机遮住约 75% 图块，只编码可见块，轻量解码器重建被遮部分。
要补得合理必须理解结构与上下文（半只火烈鸟 → 整只）。
与文本掩码语言建模同形。代表：MAE、BEiT 的表示。

5.1.2 自监督学习与预训练表示

• 图像自监督之二：对比学习



同一对象的不同视图互为**正样本**（表示接近）

不同对象为**负样本**（表示远离）

学到**对无关变化不敏感、对语义敏感**的表示

代表：SimCLR、MoCo、DINO

$$\mathcal{L}_i = -\log \left(\frac{\exp(z_i \cdot z_p / \tau)}{\exp(z_i \cdot z_p / \tau) + \sum_{n=1}^K \exp(z_i \cdot z_n / \tau)} \right)$$


Diagram illustrating the components of the SimCLR loss function:

- 正样本相似度** (Positive Sample Similarity): $\exp(z_i \cdot z_p / \tau)$
- 总体样本相似度** (Total Sample Similarity): $\sum_{n=1}^K \exp(z_i \cdot z_n / \tau)$
- 负样本相似度** (Negative Sample Similarity): $\exp(z_i \cdot z_n / \tau)$ (for $n \neq p$)

5.1.2 自监督学习与预训练表示

● 语音自监督

遮住一段语音，用前后听到的内容把它“猜”回来。



为什么不直接还原波形？

语音是连续声波，相邻采样点高度相似。


逐点还原波形容易“照抄邻近点”，学不到稳健语义。

因此通常**预测更抽象稳定的目标**，而非原始波形。

5.1.2 自监督学习与预训练表示

● 语音自监督

按**预测目标**不同，语音自监督形成两条代表路线：



wav2vec 2.0: 认向量

1
编码
波形

2
遮住
片段

3
认
向量


先将波形编码为声学向量，训练时给出“真声学向量 + 若干干扰向量”，模型要从候选中认出被遮位置的正确向量。

本质是对比学习在时间轴上的应用。

5.1.2 自监督学习与预训练表示

• 语音自监督

按**预测目标**不同，语音自监督形成两条代表路线：



HuBERT: 猜编号

1
聚类
分帧



2
产生
编号



3
猜编
号


先用 K-means 等方法把每帧语音归入类别，作为无需人工标注的“伪标签”。模型要预测被遮挡位置的类别编号。

形式上更像文本中的掩码语言建模。

5.1.2 自监督学习与预训练表示

• 语音自监督

按**预测目标**不同，语音自监督形成两条代表路线：



两种做法的预测目标不同
(认向量还是猜编号)，
但共享**同一个骨架**。


但共享同一个骨架。

5.1.3 跨模态对齐

在前两小节中我们知道了如何获得每个模态的良好向量表示，但是这些向量处于不同的语义空间中，不同模态获得的向量的每个维度表示的特征不是同一特征。这就是我们这小节需要解决的问题。

5.1.3 跨模态对齐

- 问题：各模态向量分处不同空间



换用各模态编码器各自训练，向量不在同一空间，难以直接比较。

跨模态对齐：把它们纳入同一空间，让同义对象（猫图 ↔ “猫”）彼此接近

5.1.3 跨模态对齐

● 思路：配对数据 + 对比学习

正样本配对 (图片 ↔ 文本)



一只狗在草地上
叼着飞盘奔跑。



雪山映在湖水中，
景色如画。



一杯热拿铁，
桌上散发着香气。



负样本文本 (不匹配)

一只猫咪懒洋洋地
趴在沙发上晒太阳。



城市的夜景灯火辉煌，
车流如织。



孩子们在操场上
快乐地踢足球。



负样本图片 (不匹配)



利用天然配对数据 (图文对)，让配对样本表示靠近、非配对远离——正是对比学习从“同模态不同视图”到“跨模态配对”的推广。

代表：CLIP、ALIGN

5.1.3 跨模态对齐

- CLIP: $N \times N$ 相似度矩阵


图像编码器编码后的文本向量

文本编码器编码后的文本向量

让不配对的图文向量之间的相似度下降

让配对的图文向量之间的相似度上升

以此将他们拉进同一个语义空间



5.1.3 跨模态对齐

- 对齐目标：对比损失 InfoNCE

$$\ell_i^{\text{图} \rightarrow \text{文}} = -\log \frac{\exp(\cos(\mathbf{I}_i, \mathbf{T}_i)/\tau)}{\sum_{j=1}^N \exp(\cos(\mathbf{I}_i, \mathbf{T}_j)/\tau)}$$

Softmax 函数

5.1.3 跨模态对齐

- 对齐目标：对比损失 InfoNCE

$$\ell_i^{\text{图} \rightarrow \text{文}} = -\log \frac{\exp(\cos(\mathbf{I}_i, \mathbf{T}_i)/\tau)}{\sum_{j=1}^N \exp(\cos(\mathbf{I}_i, \mathbf{T}_j)/\tau)}$$

Diagram illustrating the components of the InfoNCE loss formula:

- The numerator term $\cos(\mathbf{I}_i, \mathbf{T}_i)$ is labeled as **配对的图文相似度** (Paired image-text similarity).
- The denominator term $\cos(\mathbf{I}_i, \mathbf{T}_j)$ is composed of three parts:
 - $\mathbf{I}_i$ is labeled as **图像向量** (Image vector).
 - $\mathbf{T}_j$ is labeled as **文本向量** (Text vector).
 - τ is labeled as **温度** (Temperature).

5.1.3 跨模态对齐

- 对齐目标：对比损失 InfoNCE

$$\ell_i^{\text{图} \rightarrow \text{文}} = -\log \frac{\exp(\cos(\mathbf{I}_i, \mathbf{T}_i)/\tau)}{\sum_{j=1}^N \exp(\cos(\mathbf{I}_i, \mathbf{T}_j)/\tau)}$$

配对的图文相似度

对齐目标使该项变大

非配对的图文相似度

对齐目标使该项变小

5.1.3 跨模态对齐


• 对齐之后能做什么



图文进同一空间后，检索、图文匹配 = 算相似度
对齐后的文本表示也能作为图像生成的条件

5.1.3 跨模态对齐

● 零样本分类



把候选类别写成文本，编码后与图像算相似度，最高者即预测类别。
换候选文本即可识别新类别，无需重训 → 零样本分类。


5.1.3 跨模态对齐

• 语音-文本对齐



语音和文本之间天然存在配对关系。例如：

- 语音识别数据提供“语音-文字转写”
- 语音翻译数据提供“语音-文字翻译”

训练采用对比损失，使正确配对的表示相互靠近。



对齐前




对齐后

5.1.3 跨模态对齐

- 音频-文本对齐

更广义的音频还包括**音乐**、**动物叫声**、**交通声**和**环境声**等。
这类音频通常与“狗在吠叫”“雨声伴随雷声”等文字描述配对。



5.1.4 小结

1. 图像、语音与文本如何从原始数据转化为模型可处理的向量表示？

答：编码器/表示学习：token 化 + 自监督预训练。

2. 不同模态的表示如何在同一空间中建立语义对应？

答：跨模态对齐：通过对比学习和配对数据将不同模态向量对齐到同一空间。

下一节：

如何把这些表示接入大语言模型，构成能理解多模态、按指令做事的多模态模型。

第五讲

多模态机器学习方法与模型

肖桐

xiaotong@mail.neu.edu.cn

东北大学 计算机科学与工程学院 人工智能系 自然语言处理实验室




東北大學
Northeastern University



上节回顾:

• 表示 + 对齐




上节解决了两个问题:

表示 (原始信号 $\rightarrow$ token 向量) + 对齐
(不同模态 $\rightarrow$ 同一空间)。

现在有了表示, 但还不会 “做事” :
给一张图问 “图中有几只猫? ”, 纯表示无法回答。

本节核心问题：如何让模型“理解并回答”




本节回答：

如何把图像/语音表示接入大语言模型，让模型能理解多模态输入、按指令做事（图像问答、语音理解、多轮对话）？

5.2.1 多模态基础模型的通用结构

5.2.1 多模态基础模型的通用结构


- 三段式通用结构



本节学习如何将其他模态翻译成大语言模型可以理解的语言

5.2.1 多模态基础模型的通用结构

- 连接模块的作用




连接模块 = 翻译器，把模态编码器输出转换为语言模型可读的输入
相当于把图像/语音 “翻译” 成语言模型的 “母语”

训练常采用分阶段：先冻结两端、只训连接模块（对齐表示空间），再整体微调

5.2.1 多模态基础模型的通用结构

- 语音接入的特殊性：时序压缩




语音沿时间轴展开，
token 数量通常更多

连接模块需时序压缩（卷积下采样/池化/注意力压缩），
在保留语义与时序的前提下缩短序列 ($K \ll T$)

5.2.1 多模态基础模型的通用结构

- 小结：通用结构的共性




- 无论图像还是语音，核心都是这三段。
- 差异在连接模块如何设计、融合发生在何处。
- 下面分别看视觉语言模型和语音语言模型的具体实现。

5.2.2 视觉语言模型： 图像理解中的多模态建模

5.2.2 视觉语言模型：图像理解中的多模态建模

- 什么是视觉语言模型 (VLM)




- 视觉语言模型 (VLM) = 图像编码器 + 连接模块 + 大语言模型，能接收图像输入、围绕图像做描述/问答/推理。
- 机器学习角度：建模条件分布 $p(\text{文本} | \text{图像})$ ，图像是条件，语言模型在该条件下生成文本。

5.2.2 视觉语言模型：图像理解中的多模态建模


- 连接方法一：

使用万能转换器 **MLP** 或者**线性投影**将源模态的语义向量**映射**到LLM的语义空间中
代表工作：Llava系列



5.2.2 视觉语言模型：图像理解中的多模态建模

- 连接模块细节之一：线性投影 (LLaVA)




逐个特征独立映射； d 为词向量维度

- 最简单连接方式——用矩阵 W （或两层 MLP）把每个视觉特征独立映射到词向量同维空间，直接当视觉 token。
- 优点：结构简单、易训练；需配合好的视觉指令微调数据。

5.2.2 视觉语言模型：图像理解中的多模态建模

- 连接方法二：


使用 Learned embedding 提取图
代表工作：BLIP-2



Q-Former使用交叉注意力使Learned Queries能提取图片向量中的信息。

5.2.2 视觉语言模型：图像理解中的多模态建模

- 连接模块细节之二：Q-Former (BLIP-2)



5.2.2 视觉语言模型：图像理解中的多模态建模

- 连接方法三：

使用 VQ-VAE 家族将图像编码成离散的 token id

代表工作：Emu3




5.2.2 视觉语言模型：图像理解中的多模态建模

- 连接方法三：

使用 VQ-VAE 家族将图像编码成离散的 token id

代表工作：Emu3



0.1
0.2
-0.1
-0.2
...

codebook

索引	0	1	2	3
特征 1	0.1	-0.1	0.1	-0.1
特征 2	0.2	-0.2	0.2	-0.2
特征 3	0.05	-0.05	-0.05	0.05
特征 4	0.2	-0.2	-0.2	0.2
...	...	...	...	...


逐个比较距离

5.2.2 视觉语言模型：图像理解中的多模态建模

- 连接方法三：

使用 VQ-VAE 家族将图像编码成离散的 token id

代表工作：Emu3



编码成的向量

0.1
0.2
-0.1
-0.2
...

codebook

索引	0	1	2	3
特征 1	0.1	-0.1	0.1	-0.1
特征 2	0.2	-0.2	0.2	-0.2
特征 3	0.05	-0.05	-0.05	0.05
特征 4	0.2	-0.2	-0.2	0.2
...	...	...	...	...


逐个比较距离

5.2.2 视觉语言模型：图像理解中的多模态建模

- 连接方法三：

使用 VQ-VAE 家族将图像编码成离散的 token id

代表工作：Emu3



0.1
0.2
-0.1
-0.2
...

codebook

索引	0	1	2	3
特征 1	0.1	-0.1	0.1	-0.1
特征 2	0.2	-0.2	0.2	-0.2
特征 3	0.05	-0.05	-0.05	0.05
特征 4	0.2	-0.2	-0.2	0.2
...	...	...	...	...


逐个比较距离

5.2.2 视觉语言模型：图像理解中的多模态建模

- 连接方法三：

使用 VQ-VAE 家族将图像编码成离散的 token id

代表工作：Emu3



codebook

索引	0	1	2	3
特征 1	0.1	-0.1	0.1	-0.1
特征 2	0.2	-0.2	0.2	-0.2
特征 3	0.05	-0.05	-0.05	0.05
特征 4	0.2	-0.2	-0.2	0.2
...	...	...	...	...


逐个比较距离

5.2.2 视觉语言模型：图像理解中的多模态建模

- 连接方法三：

使用 VQ-VAE 家族将图像编码成离散的 token id

代表工作：Emu3



codebook

索引	0	1	2	3
特征 1	0.1	-0.1	0.1	-0.1
特征 2	0.2	-0.2	0.2	-0.2
特征 3	0.05	-0.05	-0.05	0.05
特征 4	0.2	-0.2	-0.2	0.2
...	...	...	...	...


和索引2最接近

5.2.2 视觉语言模型：图像理解中的多模态建模

- 连接方法三：

使用 VQ-VAE 家族将图像编码成离散的 token id

代表工作：Emu3



0.1
0.2
-0.1
-0.2
...

codebook

索引	0	1	2	3
特征 1	0.1	-0.1	0.1	-0.1
特征 2	0.2	-0.2	0.2	-0.2
特征 3	0.05	-0.05	-0.05	0.05
特征 4	0.2	-0.2	-0.2	0.2
...	...	...	...	...

编码结果 索引 2

5.2.2 视觉语言模型：图像理解中的多模态建模

- 连接方法三：

使用 VQ-VAE 家族将图像编码成离散的 token id

代表工作：Emu3



将向量离散化后，
其他模态和文本一致：都使用
离散的索引编号表示。
可以使用新的词表 embedding，
也可以使用原有的 codebook

5.2.2 视觉语言模型：图像理解中的多模态建模

● 训练范式的演进




- 早期以图文对齐预训练为主（CLIP 视觉编码器被广泛复用）；
- 视觉指令微调成为关键——LLaVA 用强文本模型自动构造 “图像 + 指令 + 回答” 数据，使模型能遵循人类指令；
- 后续工作在结构与数据上进一步扩展。
- 注意：各模型各有优劣，此处仅代表发展脉络。

5.2.2 视觉语言模型：图像理解中的多模态建模

● 视觉幻觉问题

视觉幻觉：模型有时描述图像中不存在的内容。



- 成因之一 —— 语言先验较强，模型从大量文本中学到“某场景通常包含某物”，在图像未提供证据时仍作断言。
- 抑制幻觉是多模态对齐训练的关注问题之一。

5.2.2 视觉语言模型：图像理解中的多模态建模

- 例：图像问答全流程

图像输入




问题：图中有几个苹果？

- 给定图片与问题

5.2.2 视觉语言模型：图像理解中的多模态建模


● 例：图像问答全流程



- 给定图片与问题，视觉编码器把图像转成视觉 token

5.2.2 视觉语言模型：图像理解中的多模态建模


● 例：图像问答全流程



- 给定图片与问题，视觉编码器把图像转成视觉 token，连接模块映射后与问题文本拼接，

5.2.2 视觉语言模型：图像理解中的多模态建模

● 例：图像问答全流程




- 给定图片与问题，视觉编码器把图像转成视觉 token，连接模块映射后与问题文本拼接，语言模型如同处理普通文本上下文那样自回归生成回答。
- 对模型而言，图像相当于上下文的一部分，区别在于这部分来自图像。

5.2.3 语音语言模型： 语音理解中的序列建模

5.2.3 语音语言模型：语音理解中的序列建模


• 从语音识别到语音理解



- 传统语音识别建模 $p(\text{转写} | \text{语音})$ ，只输出逐字转写 “几点开会”；
- 语音语言模型建模 $p(\text{回答} | \text{语音}, \text{指令})$ ，结合语音和指令完成问答、翻译、对话，直接回答 “下午三点”。从 “转写” 到 “理解并回应”。

5.2.3 语音语言模型：语音理解中的序列建模

• 语音如何进入语言模型：两类方法



- 连续特征接入 (Qwen-Audio/SALMONN) :
语音编码器 → 连续声学表示 → 连接模块压缩 + 投影 → 与词向量同维。
- 离散 token 接入 (SpeechGPT) : 语音先量化为离散单元, 加入语言模型词表, 统一处理文本 token 和语音 token。
- 对比: 连续接入保留更多声学细节; 离散接入形式更统一, 但量化可能损失信息。

5.2.3 语音语言模型：语音理解中的序列建模

- 语音与文本 token 的对齐


$$\mathcal{L}_{\text{speech}} = - \sum_{l=1}^L \log p \left(\underbrace{y_l}_{\text{生成的文本}} \mid \underbrace{y_{<l}}_{\text{语音连续特征}}, \underbrace{\mathbf{z}_{1:K}}_{\text{语音连续特征}}, \underbrace{\mathbf{q}}_{\text{指令}} \right),$$

- 训练时，语音与转写/翻译/回答配对。模型根据语音表示和文本指令预测目标文本。
- 必须从语音中提取与答案相关的内容，才能正确预测 → 逐渐建立语音与文本语义的对应关系。

5.2.3 语音语言模型：语音理解中的序列建模

● 训练能力的逐步扩展


语义对应 → 指令遵循 → 连贯对话



1. 语音-文本训练：用语音 + 转写/翻译数据，学习语音内容与文字对应。
2. 语音指令微调：加“语音 + 问题 + 回答”数据，扩展到问答、翻译、摘要、信息提取
3. 语音对话训练：多轮对话数据，结合前文持续理解用户语音并生成连贯回复。

5.2.3 语音语言模型：语音理解中的序列建模


• 训练能力的逐步扩展



- Whisper: 大规模语音-文本训练，跨语言跨场景识别能力强；
- SpeechGPT: 离散语音表示，语言模型接收和生成语音；
- Qwen-Audio: 扩展到语音/音乐/环境声等多种音频任务；
- SALMONN: 结合语音编码器、音频编码器与语言模型，支持识别/翻译/音频问答/情感识别。

5.2.3 语音语言模型：语音理解中的序列建模


● 现实语音中的困难



- 口语化与方言：重复、停顿、口头语、不完整句，口音与方言分布不均。
- 噪声与混响：交通声、音乐、远距离录音遮盖内容。
- 多人重叠：需判断“谁说了什么”，常需语音分离/说话人分段。
- 长语音与实时性：token 序列很长，过度压缩丢细节，保留全部又增加计算量和延迟。

5.2.3 语音语言模型：语音理解中的序列建模

• 转写 & 语音理解




- 语音理解不是先转写再让语言模型回答。
- 逐字转写只保留“说了什么”，丢失语气、情绪、停顿、说话人、环境声。
- 因此语音语言模型通常需直接读取声学表示，而不能只依赖转写文本

5.2.4 多模态指令微调与对 齐

5.2.4 多模态指令微调与对齐


• 为什么需要指令微调与对齐



- 模型具备图像/语音输入能力后，仍需指令微调学会理解用户意图、按规定格式作答，再通过偏好对齐（RLHF/DPO）使输出符合人类偏好与安全要求。
- 方法本身已在第三部分讨论，本小节只说多模态情形的特殊之处。

5.2.4 多模态指令微调与对齐

● 多模态指令微调的特殊性




- 指令数据须包含非文本模态：“图像/语音 + 指令 + 目标回答”（如图像问答、图像描述、图文推理）。构造成本高 → 实践中常借助强文本模型，依据图像的文字标注自动生成大量问答样本（LLaVA）。
- 对齐须兼顾模态一致性：除有用性与安全性外，还需抑制视觉幻觉，使回答忠实于实际输入的图像/语，而非依赖语言先验臆测。

5.2.5 图像—语音—文本联合建模


5.2.5 图像—语音—文本联合建模

- 为什么需要联合建模



5.2.5 图像—语音—文本联合建模


• 以语音/音频为时间轴



- 视频/课堂/会议中，语音或音频沿时间连续展开，可作组织其他模态的时间轴。
- 模型需把同一时刻附近的画面、声音、字幕组合起来，才能完整理解正在发生的事件。
- 视频理解：画面 + 语音 + 环境声 + 字幕互补（敲门声提示画面外事件）；
- 看图讲解：根据图像 + 文本生成语音讲解，控制语速/停顿/语气。


5.2.5 图像—语音—文本联合建模

• 长上下文中的时间同步



- 长视频/课堂录音/多人会议 → 切分为若干时间片。
- 模型需保留时间片先后顺序，正确判断一句话、一个动作、一种声音是否发生在同一时刻。
- 时间对齐错误 → 把后面的声音解释为前面的画面 → 错误事件描述。

5.2.5 小结



- 通用结构：编码器（感知）→ 连接模块（翻译）→ 语言模型（理解 + 表达）
- 视觉语言模型：
三种连接方式（线性投影/Q-Former/离散的token），关键在视觉指令微调
- 语音语言模型：时序压缩 + 连续/离散接入，从转写扩展到理解
- 指令微调与对齐：包含非文本模态的指令数据 + 抑制视觉幻觉
- 联合建模：多模态并存，以时间轴组织，保持语义/空间/时间一致

5.2.5 小结

下一节：


如何让模型不只“理解”，还能“生成”

——文本生成图像、图像编辑、语音合成、音频生成，统一的条件生成框架。

5.3 条件生成建模与多模态内容生成

从理解到生成

- 上节回顾：让模型 “理解” 多模态输入



上节解决了 “输入” 问题——图像/语音接入大语言模型，模型能看懂、听懂、回答。

那么，给一句话 “一只戴红帽子的柯基坐在草地上”，能不能让模型画出来？给一段文字，能不能让模型读出来？

从理解到生成

- 本节核心问题：统一的条件生成框架

条件

学习 $p(x|c)$ 并从中采样得到新的 x .

生成对象

文生图、图像编辑、语音合成、文生音频，表面各异，但都可写成同一个数学问题：给定条件 c ，学习目标 x 的条件分布并采样。 c 可以是文本/图像/语音/指令； x 可以是图像/语音/音频。

本节地图：生成基础 (5.3.1) → 文生图 (5.3.2) → 图像编辑 (5.3.3) → 语音生成 (5.3.4) → 音频生成 (5.3.5) → 跨模态交互生成 (5.3.6)


阅读每种任务时，请对照此式，明确 c 和 x 各指什么。

5.3.1 条件生成模型基础

5.3.1 条件生成模型基础

- “生成” 就是 “采样”

高维图像空间（二维投影示意）





以图像为例，“所有可能图像”构成的空间上存在分布 $p(x)$ ——自然图像所在区域概率高，杂乱组合概率低。

采样 = 按该分布抽取一个具体取值。机器学习中的“生成”，大体就是从分布中采样。

概率分布：对所有可能取值给出概率/概率密度。

5.3.1 条件生成模型基础

● 文本采样 vs 图像采样：同一套逻辑




语言模型逐步生成时，每一步给出“下一个词”的概率分布，再采样——这是采样文字。

图像生成是在图像分布上采样一个高维向量——这是采样向量。

无论离散的词还是连续的图像向量，都遵循
“先有分布、再采样”

5.3.1 条件生成模型基础

- 判别模型 vs 生成模型 vs 条件生成模型



判别模型：学 $p(y | x)$ ，由输入预测标签，关注分界（此前多数任务）。

生成模型：学数据本身的分布 $p(x)$ ，学成后可采样出新样本。

条件生成模型：引入条件 c ，学 $p(x | c)$ ，按指定条件采样（“生成一只猫”而非任意图像）。多模态生成中， c 正是连接不同模态的纽带：文本作图像生成的条件，原图 + 指令作图像编辑的条件。

5.3.1 条件生成模型基础

● 常见生成建模方法一览

方法	核心思想	代表
自回归	按顺序逐元素建模 $p(x) = \prod_t p(x_t \mid x_{<t})$ ，逐步采样	语言模型、图像自回归
变分自编码器	引入隐变量，优化重建与分布约束的折中	VAE
生成对抗网络	生成器与判别器对抗，提升样本逼真度	GAN
扩散模型	正向逐步加噪、反向逐步去噪并采样	DDPM
基于流的模型	以可逆变换在简单分布与数据分布间建立映射	Normalizing Flow


历史上发展出多条路线——自回归、VAE、GAN、扩散模型、流模型。本节以扩散模型为主线，因其近年在图像/语音/音频生成中应用最广。共同点：都要回答 “如何建模分布并采样”。

5.3.2 文本生成图像

5.3.2 文本生成图像

• 文生图的方法演变


文生图建模 $p(\text{图像} / \text{文本})$ 。



早期用 GAN 直接生成；DALL·E 把图像离散为 token 后自回归生成；此后扩散模型成为主流；潜在扩散模型在低维潜在空间做扩散，显著降低计算成本（Stable Diffusion 的基础）。下面以扩散模型为例说明训练与采样过程。

5.3.2 文本生成图像

- 扩散模型基本思想：加噪与去噪



正向过程：对真实图像 x_0 逐步加高斯噪声， T 步后接近纯噪声 x_T （预设，无需学习）。

反向过程：训练网络从带噪图估计所含噪声，逐步去噪。生成时从纯噪声出发，反复去噪，还原出图像。

5.3.2 文本生成图像

- 训练目标：学会估计噪声

扩散t步后的图片

原始的清晰图片

噪声

训练目标

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

预设的超参数

损失函数

$$\mathcal{L}_{\text{diff}} = \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}, t} \left\| \boldsymbol{\epsilon} - \boldsymbol{\epsilon}_{\theta}(\mathbf{x}_t, t, \mathbf{c}) \right\|_2^2$$

要训练的神经网络

条件 (文本指令)

5.3.2 文本生成图像

- 采样：从噪声“显影”出图像

按概率采样

$$\mathbf{x}_{t-1} \sim \mathcal{N}\left(\mu_{\theta}(\mathbf{x}_t, t), \tilde{\beta}_t \mathbf{I}\right)$$

正态分布

均值向量

协方差
矩阵

预设的超
参数

等价

$$\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta}(\mathbf{x}_t, t, \mathbf{c}) \right) + \sigma_t \mathbf{z}, \quad \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

第t-1步扩
散图片

第t步扩散
图片

神经网络预
测的噪音(训
练获得)


扩散步

条件

从正态分布
中采样出来
的噪音

5.3.2 文本生成图像

- 采样：从噪声 “显影” 出图像



直观地看，就是图像 “从噪声中逐步显影”：轮廓、颜色、细节逐渐浮现

5.3.2 文本生成图像

- 增强文本一致性：无分类器引导

图片从无条件向条件c方向移动

$$\tilde{\epsilon}_{\theta}(\mathbf{x}_t, \mathbf{c}) = \epsilon_{\theta}(\mathbf{x}_t, \emptyset) + w \left(\epsilon_{\theta}(\mathbf{x}_t, \mathbf{c}) - \epsilon_{\theta}(\mathbf{x}_t, \emptyset) \right)$$


有条件预测
的噪声

无条件预测
的噪声

每步同时计算 “给条件” 与 “不给条件” 两种噪声估计，放大二者之差。

5.3.2 文本生成图像


- 增强文本一致性：无分类器引导



w (引导强度) 越大, 结果越贴合文本, 但多样性可能下降, 需要权衡

5.3.2 文本生成图像

例：



生成




生成图像

条件

5.3.3 图像编辑：约束条件下的生成

5.3.3 图像编辑：约束条件下的生成

● 图像编辑




5.3.3 图像编辑：约束条件下的生成

● 图像编辑



5.3.3 图像编辑：约束条件下的生成


- 图像编辑的一般形式



以原图和某种编辑条件为输入，交由生成模型（多为扩散模型）产生结果。不同代表工作的差异，主要在于“编辑条件”取何种形式。

5.3.3 图像编辑：约束条件下的生成

● 四类编辑条件



图像修复与扩展：掩码约束 “仅在此处生成”。


文本引导编辑：自然语言描述目标，尽量保留原图

指令式编辑：直接给编辑命令，如 “将天空改为黄昏”

结构控制与身份保持：边缘图/深度图/姿态骨架固定构图；少量参考图
保持对象身份

5.3.3 图像编辑：约束条件下的生成

● 例：结构控制 + 指令式编辑



结构控制：给定结构条件图（姿态骨架/线稿/深度图）+ 文本，模型在保持结构前提下按文本生成内容。

指令式编辑：模型据指令仅改动指定部分（背景/光照），主体保持一致。评价图像编辑需看三点：目标改动是否准确实现、不应改动之处是否保持、局部修改是否协调

5.3.4 语音生成：连续信号的条件生成

5.3.4 语音生成：连续信号的条件生成

- 语音合成建模

$$p(\text{语音} \mid \text{文本, 说话人, 风格, 情感}).$$


将条件生成框架中 x 取语音、 c 取文本 + 说话人 + 情感等，即得语音合成。

与图像生成的根本差异：

图像多为空间结构的一次性生成，语音是随时间展开的连续序列生成。
好的语音合成不仅要传达内容，还需自然的音色、韵律、语速、停顿。

5.3.4 语音生成：连续信号的条件生成

- 文本到语音的基本流程




三个部分：文本前端（文字规范化 → 字符/音素）→ 声学模型（据文本预测梅尔频谱或声学 token）→ 声码器（还原为可播放波形）。说话人、风格、情感等条件在声学模型这一步注入。

5.3.4 语音生成：连续信号的条件生成

- 语音生成的“一对多”特性

同一句文本可对应多种正确读法，语音生成是“一对多”任务



说话人条件决定声音像谁；


音高/时长/能量影响语速/
重音/停顿/语气；

情感标签控制表达方式。

模型需同时满足：内容易懂、声音自然、符合指定说话人和风格。

5.3.4 语音生成：连续信号的条件生成

● 零样本合成与声音克隆




多说话人模型从参考语音提取音色和风格，用该声音朗读新文本。

参考语音提供 “用谁的声音说”，输入文本提供 “说什么”。

5.3.4 语音生成：连续信号的条件生成


● 零样本合成与声音克隆

若能为训练中未出现的说话人直接生成语音（无需重训），即零样本语音合成。



5.3.4 语音生成：连续信号的条件生成

- 代表工作 & 声音克隆的伦理问题



声音克隆的安全与伦理：声音有明显个人身份属性，未经许可复制他人声音可能被用于冒充、虚假信息、诈骗。实际系统应确认授权、标识合成内容、限制高风险场景克隆，结合音频水印等措施降低滥用风险。

5.3.5 音频生成：声音事件与声景的条件生成

5.3.5 音频生成：声音事件与声景的条件生成

● 一般音频生成建模

$$p(\text{音频} \mid \text{文本描述})$$

文本描述

“雨夜的街道上有汽车经过”

给出场景语义

生成

生成音频场景



雨声

车辆声


空间环境

音频生成据文字描述生成此类声音。与语音合成都生成连续信号，但语音有明确语言内容和发音规则，一般音频更强调声音事件、环境层次、时间变化，常有多声源叠加，建模难度往往更高。

除语音外，还有更广泛的声音——环境声、音乐、声音事件、复杂声景。

5.3.5 音频生成：声音事件与声景的条件生成

● 文本到音频的基本流程



文字描述编码为条件表示，生成模型据此产生频谱/潜在表示/离散音频 token，最后还原为音频波形。

同一框架也可扩展为编辑：接收原始音频 + 编辑指令（“加入鸟叫声”），生成编辑后音频。

5.3.5 音频生成：声音事件与声景的条件生成

● 声音事件 vs 声景：时间结构是关键

声景理解示意

声景例句 “雨声中，远处有汽车驶过，随后传来雷声”

声音种类

雨声

汽车声

雷声

背景环境

雨夜

街道

远处空间

发生顺序

雨声

汽车驶过

随后雷声

背景雨声

→

汽车驶过

→


雷声出现

时间

简单目标是生成单个声音事件（狗叫/玻璃破碎/汽车鸣笛）；
复杂的声景包含多个同时或依次出现的声源，需确定每种声音何时开始、持续多久、如何叠加。
音频生成三要求：内容一致、音质真实、时序正确。
同一段文字可能对应多种合理声音——模型学的是分布，不是唯一答案。

5.3.5 音频生成：声音事件与声景的条件生成

- 音频上的扩散建模




与图像扩散思路一致：训练时逐步加噪，生成时从随机噪声在文字条件引导下反复去噪。

为降低计算量，通常先将音频压缩为频谱或低维潜在表示，再通过解码器和声码器恢复波形。

在潜在空间去噪，再通过解码器和声码器恢复波形。文字表示在每步去噪中提供条件。

5.3.5 音频生成：声音事件与声景的条件生成

• 代表工作



AudioGen: 音频量化为离散 token, 自回归预测;

AudioLDM/Make-An-Audio: 扩散模型应用于压缩后的音频表示, 提升效率与音质;

Make-An-Audio 2: 强调声音事件先后顺序和长音频时间一致性;

AUDIT: 用“原始音频 + 编辑指令 + 目标音频”训练潜在扩散模型, 执行添加/删除/替换/修复等编辑。

音频生成 = 语音合成从“人类说话声”向一般声音的推广。

5.3.6 跨模态交互生成

5.3.6 跨模态交互生成


- 从单向生成到多条件交互生成

$p(\text{目标模态} \mid \text{文本, 图像, 语音, 历史上下文, 用户指令}).$

前述任务多为单一条件、单向生成。
更接近实际应用的是多条件、多模态、多轮交互

5.3.6 跨模态交互生成


- 语音/音频作为目标或条件



语音和音频既可作模型需生成的目标（视频配音、看图讲解——需保证内容与画面一致，且停顿/语速/音效时间与视频同步），也可作理解用户意图的条件（“把背景音乐调小一点” “在开门时加入脚步声”——需结合当前结果和历史指令，只改指定部分）。

5.3.6 跨模态交互生成


• 多轮交互生成 & 一致性要求



每轮根据新指令修订结果，而非完全重新生成
需同时考察：语义是否相符、声音事件与动作是否同步、
是否只改指定内容、声音是否自然真实、
多轮修改后人物/音色/场景是否保持一致。

5.3.6 跨模态交互生成

● 统一任意模态生成：CoDi



CoDi 等统一多模态生成模型尝试把文本、图像、视频、音频纳入同一框架，使一个或多个模态的组合能控制另一模态的生成。

关键不只是“能生成多种模态”，还在于不同输出应描述同一事件，在空间、时间、语义上保持协调。

本节小结 & 全章回顾

本节小结 & 全章回顾

学习 $p(x | c)$ $\implies$ 从中采样得到新的 x

任务	条件 c	生成对象 x
文生图	$c = \text{文本描述}$	$x = \text{图像}$
图像编辑	$c = \text{原图} + \text{编辑指令}$	$x = \text{编辑后图像}$
语音生成	$c = \text{文本} + \text{音色} / \text{说话人条件}$	$x = \text{语音}$
音频生成	$c = \text{文本描述} / \text{声景条件}$	$x = \text{音频}$
交互生成	$c = \text{多模态输入} + \text{历史上下文} + \text{指令}$	$x = \text{目标模态}$